


因果推断在飞猪广告 预算分配中的应用



目录

contents

01

平台视角下的广告预算分配

02

因果推断技术

03

因果推断在广告策略中的实践

04

未来思考

1

平台视角下的广告预算分配

平台视角下的广告预算分配

预算分配：多目标优化问题



$$\begin{aligned}
 & \max. X_{ij} * KPI(ecpm, ctr_{ad}, cvr_{ad}, gmv_{ad}, revenue_{ad}) \\
 & s. t. \sum_j X_{ij} * ctr_{ij} * bid_{ij} \leq budget_i \\
 & \quad \frac{\sum_j X_{ij} * gmv_{ij}}{\sum_j X_{ij} * ctr_{ij} * bid_{ij}} \geq ROI_i \\
 & \quad \frac{\sum_{ij} ctr_{ij}}{\sum_{ij} 1} > ctr_{thres} \\
 & \quad \sum_{ij} gmv_{ij} > gmv_{thres} \\
 & \quad \sum_{ij} revenue_{ij} > revenue_{thres} \\
 & X_{ij} := I(\text{delivery ad } i \text{ on pv } j)
 \end{aligned}$$

平台视角下的广告预算分配

常用控制算法

- PID
- 对偶法（基于线性规划）
- 线性插值

共同特点：需要线性因子

常用控制对象

- Bidding
- CTR/CVR thresholds
- 参竞概率（Throttling Prob.）

OCPX：按转化成本出价, $\text{bid} = \text{CPA} * \text{CVR} * \text{price} * \alpha$

$p(\text{deliver}) = I(p\text{CTR} \geq \text{CTR_th} \text{ and } p\text{CVR} \geq \text{CVR_th})$

$p(\text{deliver}) = f(p\text{CTR}, p\text{CVR}, \dots)$

平台视角下的广告预算分配

平台侧 KPI 的控制 --- 以 GMV 为例

难点：现有策略因子中，不存在平台 GMV 的线性因子
--- 直接使用 pCTR、pCVR 行吗？

常用策略因子

- pCTR
- pCVR
- Bidding landscape




使用因果推断的语言建模

$$\begin{aligned} effect_{ad} &= GMV(T = 1|X) - GMV(T = 0|X) \\ T &:= I(\text{deliver } ad) \end{aligned}$$


2

因果推断技术



因果推断技术

基本问题



因果推断技术

The Ignorability Assumption

朴素思想：我们要推断某个处理的效应，必须控制其它相关因子

两大实现路径

1. 随机实验（切断 $X \rightarrow T$ ）：若 T 的分配是随机的，则 T 与任何变量独立

2. 特征工程（切断 $X \rightarrow T$, $X \rightarrow Y$ ）：若 X 包含所有confounders

--- confounders: 同时影响 T 与 Y 的变量

--- 给定 X ，不同 treatment group 下影响 Y 的协变量分布相同



$$Y(T = t) \perp T | X$$

为什么有效？

数学上理解：
$$E(Y(T = t) | X = x) = E(Y(T = t) | T = t, X = x) = E(Y^F | T = t, X = x)$$

常识上理解：每组特征下可视为随机实验，得到局部的无偏估计，那么任意样本上的效应，可以在相应 X 的分布上积分得到。

因果推断技术

从机器学习视角审视

$$\begin{aligned} effect_{ad} &= GMV(T = 1|X) - GMV(T = 0|X) \\ T &:= I(\text{deliver ad}) \end{aligned}$$

挑战1：样本结构上，两组样本分布需相近，否则存在误差累计效应

--- 一般预测问题上，只需样本整体无偏即可

挑战2：对变量 T 的推断需准确，这并不是机器学习擅长的工作


--- 传统的统计模型，我们通过对数据引入假设，可以推断参数分布

--- 大数据时代的算法模型，往往关注预测精度而非统计推断能力


因果推断技术

样本结构问题

Y: 单UV转化




随机实验



- 成本过高, 难以落地

后采样



- How?

特征工程

- 若 X 包含所有 confounders, 则虽 $P(T, Y)$ 不同, 但 $P(T, X, Y)$ 相同
- 实际上很难做到

因果推断技术

变量的统计推断问题

通过模型结构先验和 loss 设计，促使模型对 treatment 学习到正确的效应

3

因果推断在广告策略中的实践

因果推断在广告策略中的实践

工程化落地方案

基于观察数据的综合方案

特征工程

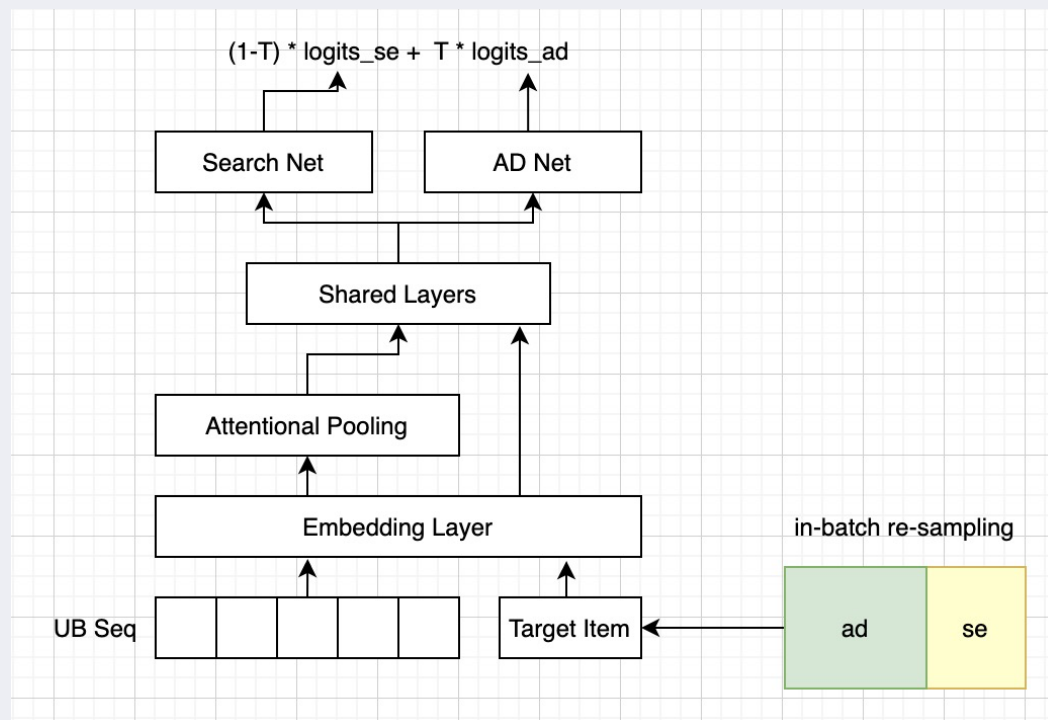
confounders捕捉

- AD pCTR/pCVR
 - Transfer learning from Search Data
- Search Rank Queue
- User Profiles

样本重采样

如何构造分布相似的两组样本

- Propensity Score Weighting
- Propensity Score Matching
- Original Space Matching



因果推断在广告策略中的实践

工程化落地方案

基于观察数据的综合方案

模型设计

如何捕捉 treatment 变量的效应

- Treatment embedding & shortcut connection
- Domain adaption: Multi-task learning
- Structure regularization
 - effect net
- Task regularization (todo...)
 - balanced representation learning

因果推断在广告策略中的实践

样本重采样

Propensity Score Weighting/Matching

- 基于样本被分配到处理组的概率重采样
- 采样结果与随机分组相似
- 但是Propensity Score本身的准确估计很困难

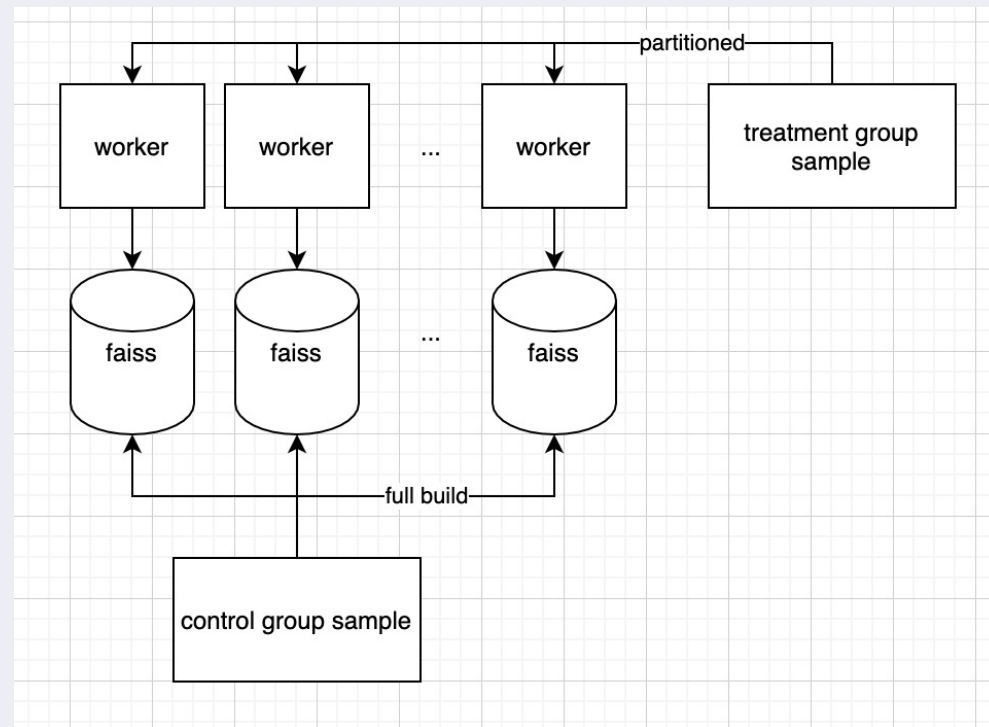


Original space matching

- 直接在特征空间进行匹配
- 需要注意分析样本分布
- 广告业务中为什么可行

Search Results



pCTR=0.8
pCTR=0.7
pCTR=0.6
pCTR=0.5
...



$$\vec{V}_{match} = [0.8, 0.7, 0.6, 0.5, \dots]$$

因果推断在广告策略中的实践

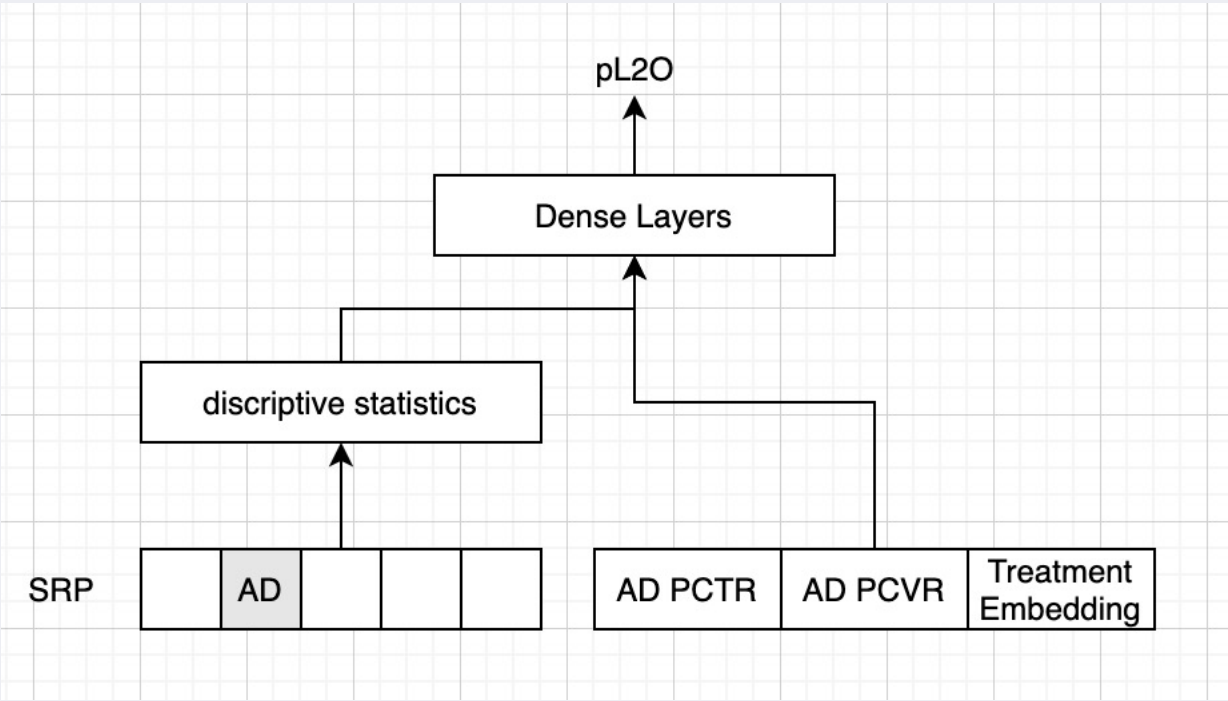
Uplift evaluation简介



因果推断在广告策略中的实践

Direct Method

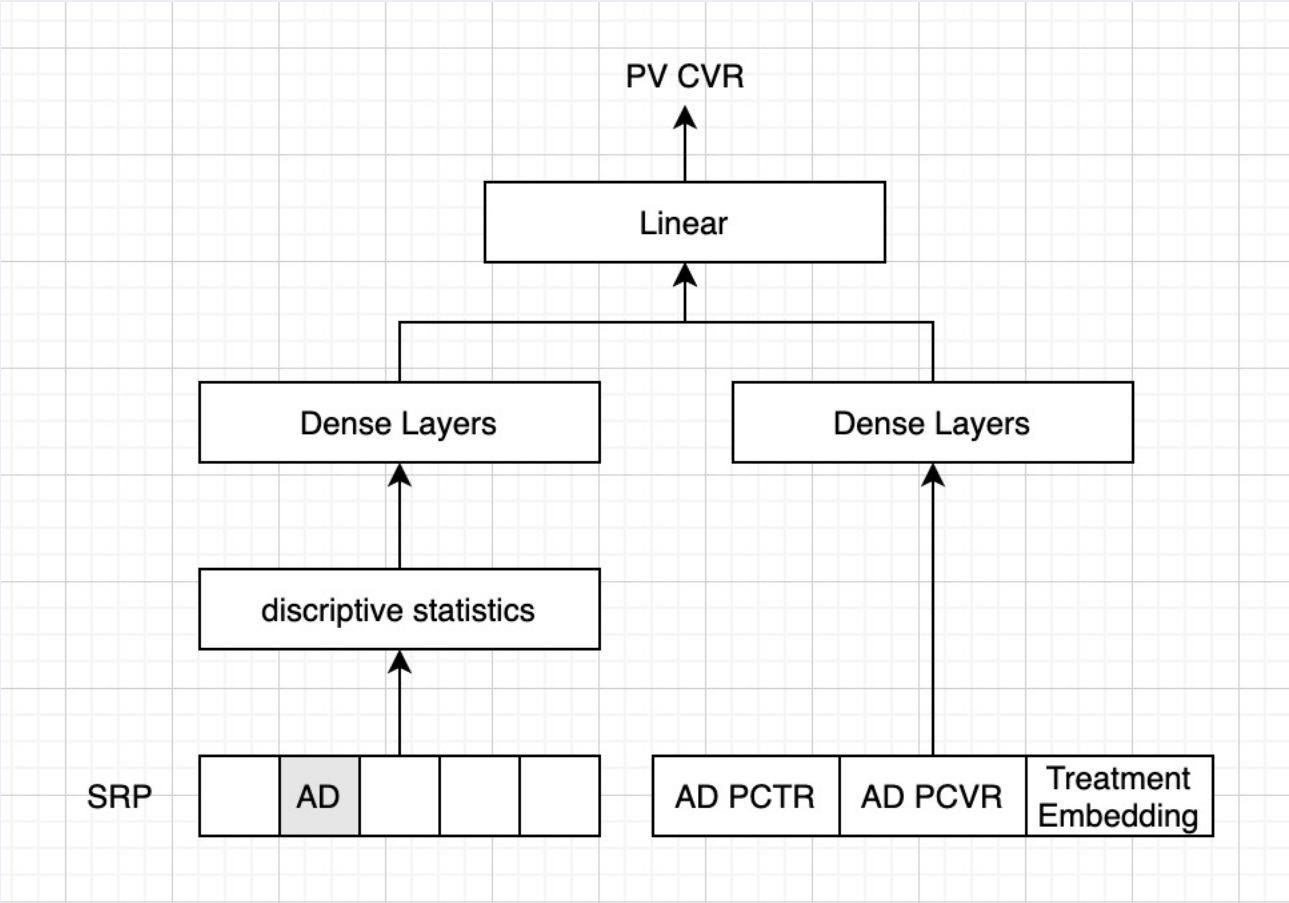
将 treatment 作为一般特征建模



Method	L2O AUC	Uplift Curve Gini
max pCTR*pCVR delta pCTR*pCVR	0.736	-0.01
DM w/o matching	0.744	-0.06
DM	0.740	+0.03

因果推断在广告策略中的实践

Direct Method with Shortcuts

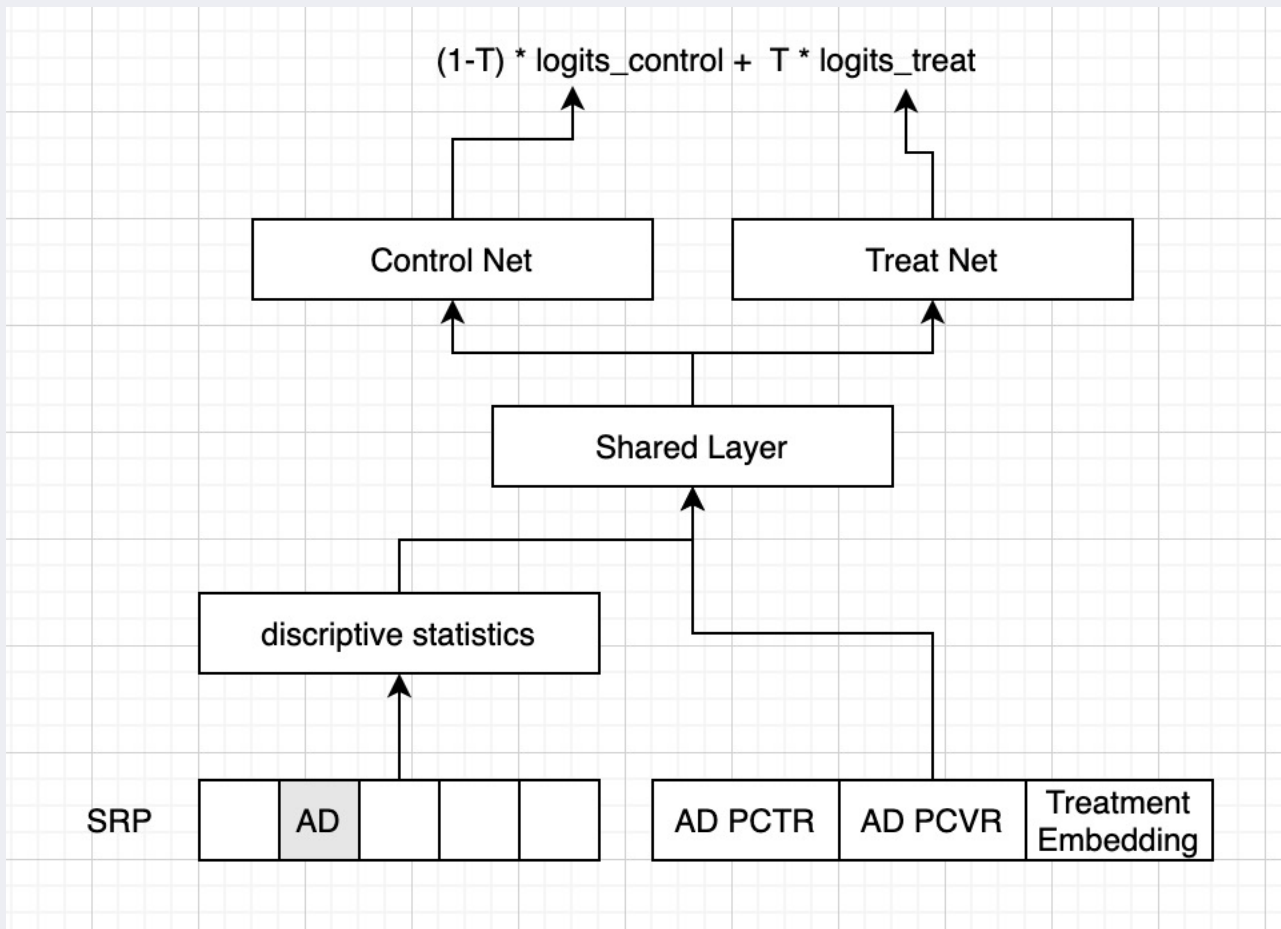


Method	L2O AUC	Uplift Curve Gini
max pCTR*pCVR delta pCTR*pCVR	0.736	-0.01
DMS w/o matching	0.742	-0.01
DMS	0.739	+0.06

因果推断在广告策略中的实践

Domain-Adaption: Multi-task Learning

从特征到参数

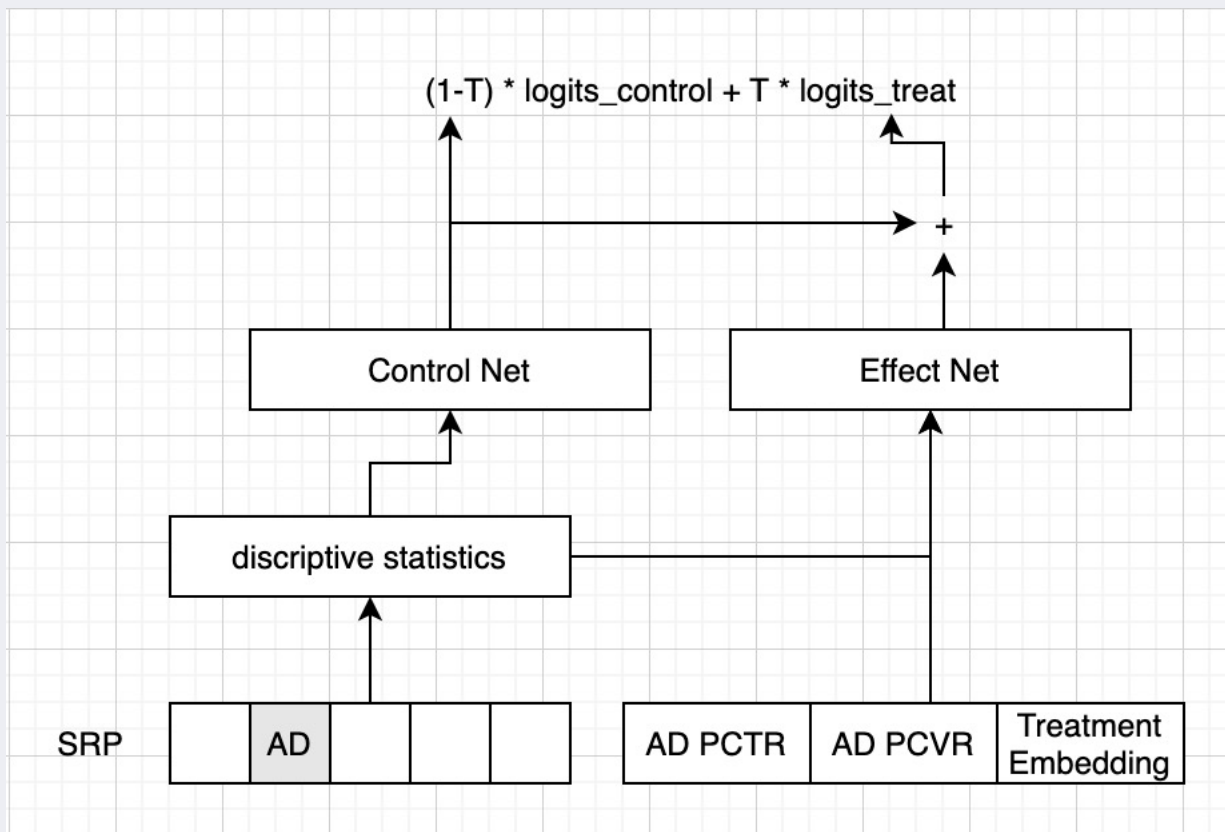


Method	L2O AUC	Uplift Curve Gini
max pCTR*pCVR delta pCTR*pCVR	0.736	-0.01
MTL w/o matching	0.752	-0.06
MTL	0.748	+0.11

因果推断在广告策略中的实践


Effect-Net

显式建模 treatment effect, 使其与原生搜索pv的转化预估构成加性的先验关系



Method	L2O AUC	Uplift Curve Gini
max pCTR*pCVR delta pCTR*pCVR	0.736	-0.01
EN w/o matching	0.749	+0.08
EN	0.745	+0.10

4 未来思考



未来思考

因果推理与深度表示学习的关系

- 怎样的表征是有利于因果效应的估计的?
- 如何理解表征与 confounder 的关系?
- 表征学习在 debiasing、模型泛化等问题中的应用


相关研究方向: Balanced Representation Learning

- F. Johansson, U. Shalit, and D. Sontag, "Learning representations for counterfactual inference," in *International conference on machine learning*, 2016, pp. 3020-3029.
- U. Shalit, F. D. Johansson, and D. Sontag, "Estimating individual treatment effect: generalization bounds and algorithms," in *Proceedings of the 34th International Conference on Machine Learning-Volume 70*, 2017: JMLR. org, pp. 3076-3085.
- L. Yao, S. Li, Y. Li, M. Huai, J. Gao, and A. Zhang, "Representation learning for treatment effect estimation from observational data," in *Advances in Neural Information Processing Systems*, 2018, pp. 2633-2643.
- H. Liu, Y. Li, Q. Cao, G. Qiu, and J. Chen, "Estimating Individual Advertising Effect in E-Commerce," *arXiv preprint arXiv:1903.04149*, 2019.

未来思考

Balanced Representation Learning

促使两组样本中学习到的 representation 分布相似



$$\begin{aligned} \epsilon_{PEHE}(h, \Phi) &\leq \\ 2(\epsilon_{CF}(h, \Phi) + \epsilon_F(h, \Phi) - 2\sigma_Y^2) &\leq \\ 2(\epsilon_F^{t=0}(h, \Phi) + \epsilon_F^{t=1}(h, \Phi) + B_\Phi IPM_G(p_\Phi^{t=1}, p_\Phi^{t=0}) - 2\sigma_Y^2), \end{aligned} \quad (2)$$

U. Shalit, F. D. Johansson, and D. Sontag, "Estimating individual treatment effect: generalization bounds and algorithms," in *Proceedings of the 34th International Conference on Machine Learning-Volume 70*, 2017: JMLR. org, pp. 3076-3085.

思考

好的方向，但是现有的工作仍有很大改进空间

- IPM as a treatment ...
- Low IPM -> missing confounder



Thanks you



海量 HC
mingyuan.tmy@alibaba-
inc.com