

# 因果推断在哈啰智能营销的应用

董彦燊 哈啰出行 算法工程师

# 目录

01

因果推断简介

02

因果推断&智能营销

03

因果推断：Uplift建模

04

因果推断在哈啰的应用




PART 01

# 第一部分 因果推断简介

- 相关性vs因果性
- 因果推断研究问题&研究方法

# 因果推断

因果性&相关性



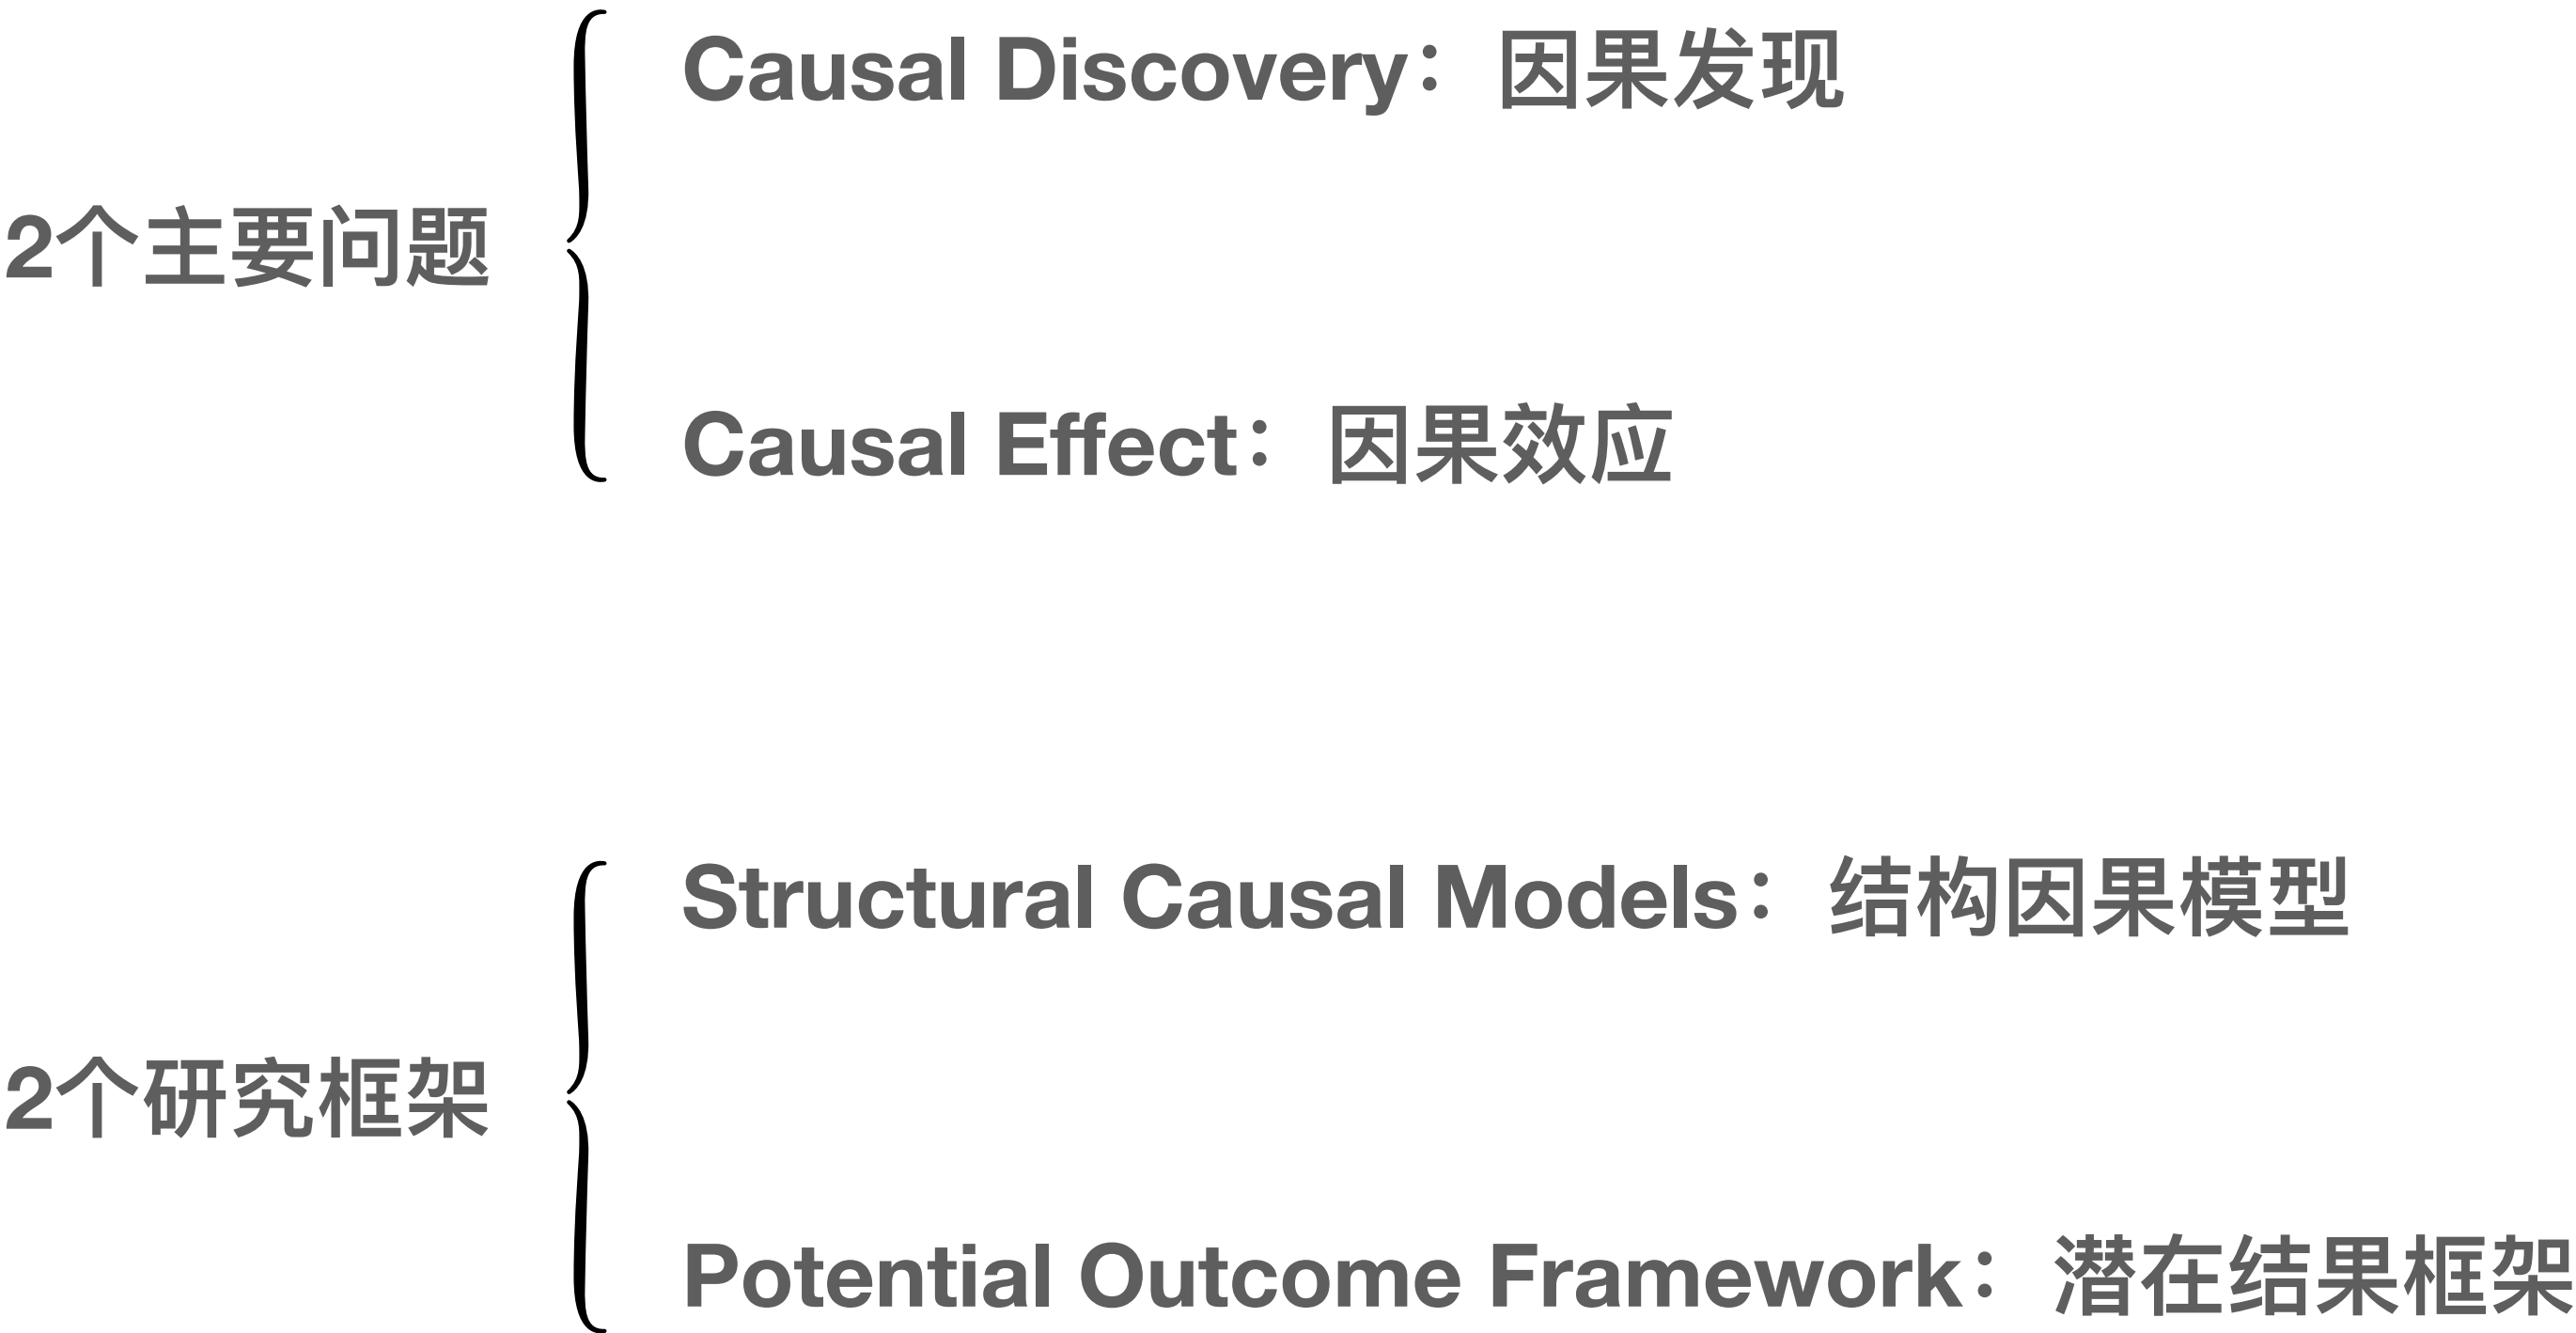
天气与用电量有因果关系：气温上升导致用电量上升

天气与冰淇淋销量有因果关系：气温上升导致冰淇淋销量上升

用电量与冰淇淋销量有相关性：没有因果关系

# 因果推断

## 研究问题&研究方法





PART 02

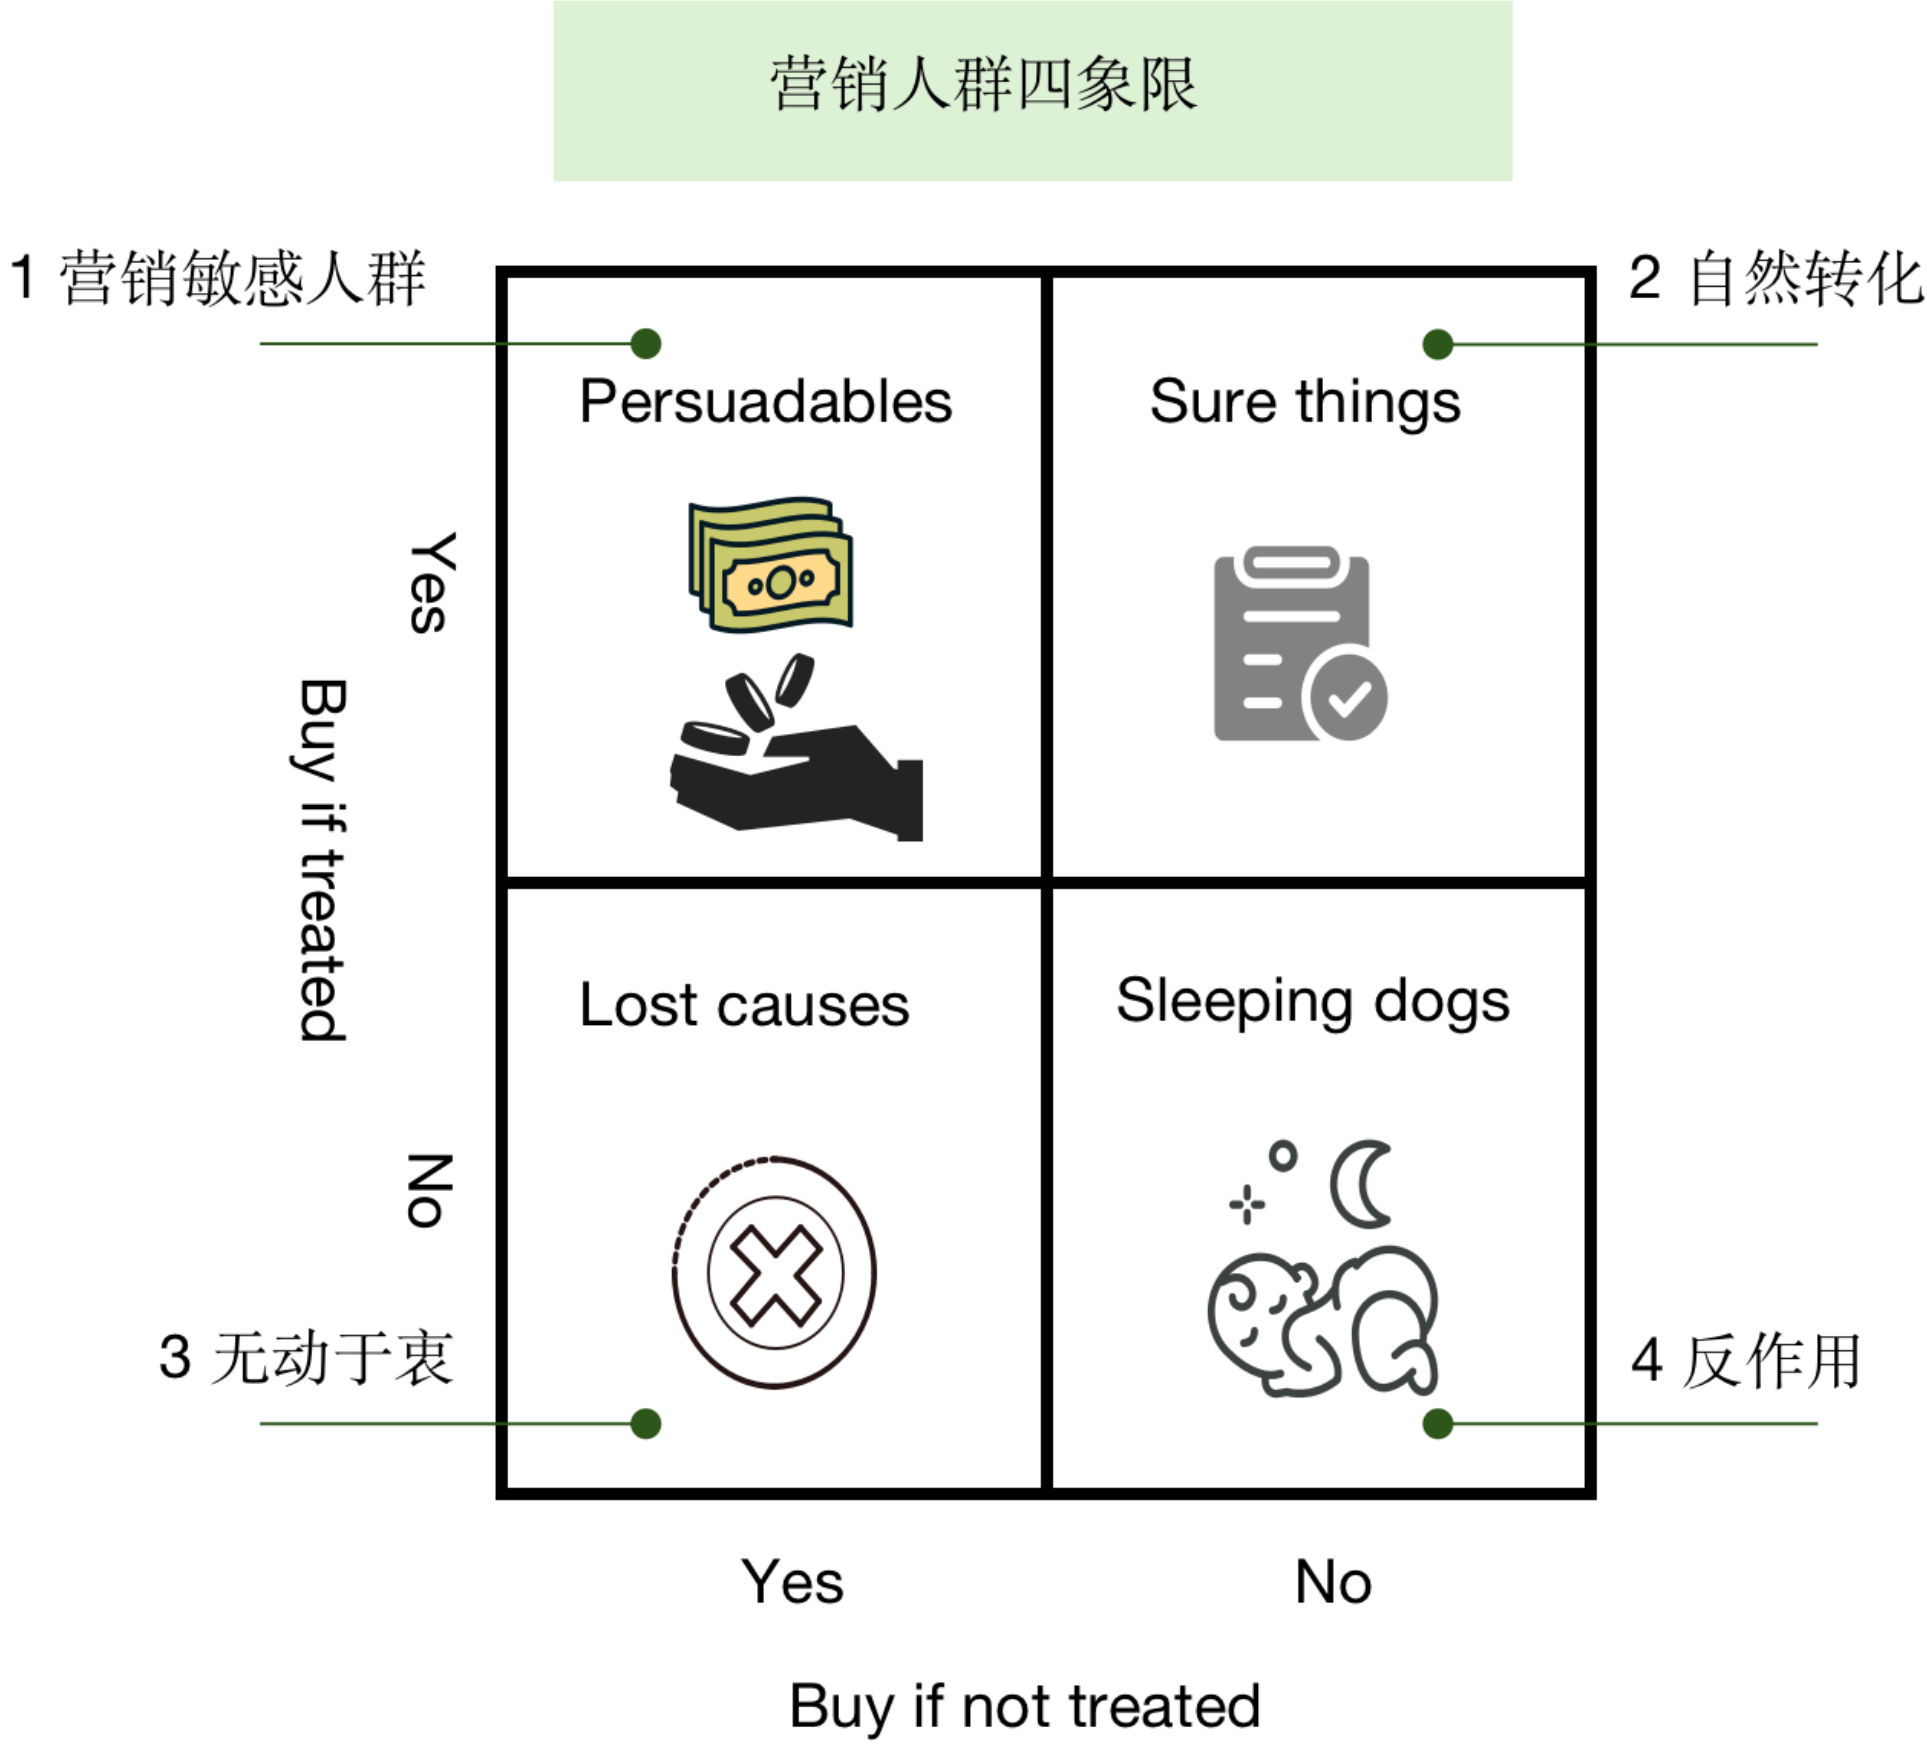
## 第二部分 因果推断&智能营销

- 传统方法
- 因果效应



# 因果推断&智能营销

## 营销4象限

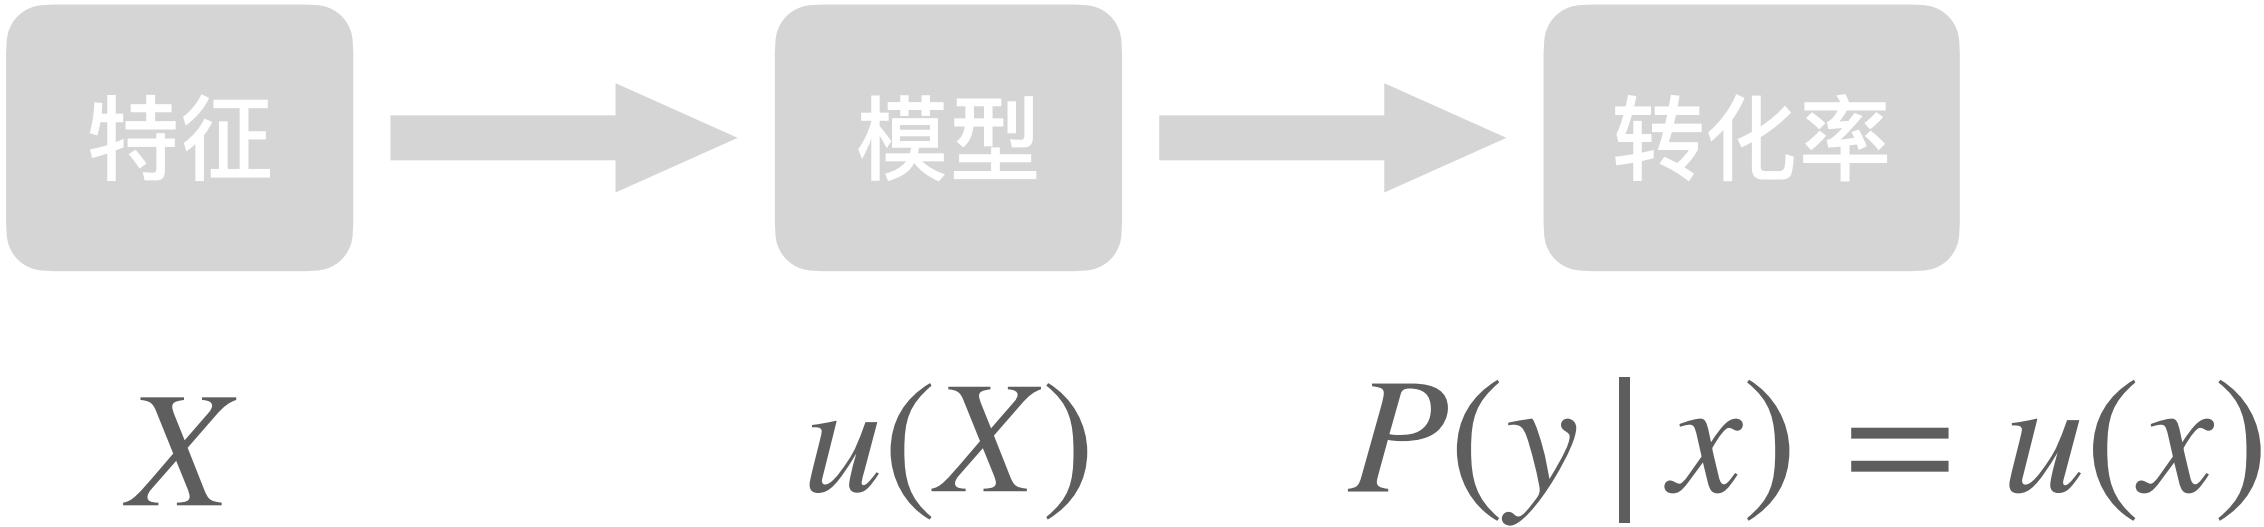


营销敏感人群：无券不购买，发券才购买  
自然转化：无论有没有发券，都会购买  
无动于衷：无论发不发券，都不会购买  
反作用：无券会购买，发券反而不购买

通过发放优惠券，促使用户转化

# 因果推断&智能营销

智能营销-传统方法



	发券购买率	无券购买率
用户1	1.3%	0.8%
用户2	1.5%	1.4%

根据模型预测结果决定是否给用户发券

机器学习模型预估发放优惠券时用户的转化率



# 因果推断&智能营销

传统方法是否最优解？

给用户2发券是否为最优解？

	发券购买率	无券购买率
用户1	1.3%	0.8%
用户2	1.5%	1.4%

相关性模型预测结果

1.5% > 1.3%  
1不发2发？

假设用户1和用户2各10000人，  
不发券价格10元、发券后价格8元，  
如何收益最大化？

	发券	不发券
用户1	1040	800
用户2	1200	1400

发券和不发券分别带来的收益

都不发券： $10000 \times 0.8\% \times 10 + 10000 \times 1.4\% \times 10 = 2200$   
都发券： $10000 \times 1.3\% \times 8 + 10000 \times 1.5\% \times 8 = 2240$   
1不发2发： $10000 \times 0.8\% \times 10 + 10000 \times 1.5\% \times 8 = 2000$   
1发2不发： $10000 \times 1.3\% \times 8 + 10000 \times 1.4\% \times 10 = 2400$

# 因果推断&智能营销

## 因果效应

**Treatment Effect:** 干预因素变化对目标结果的影响。

**问题设定:** 研究给用户发放优惠券对用户转化率的影响，那么是否发放优惠券就是treatment，假设treatment有两种  $t \in \{0,1\}$ ，对于用户  $i$ ，目标结果为转化率  $y$ ， $y^t$  表示treatment为  $t$  时的转化率。

**Individual Treatment Effect:**  $ITE_i = \tau_i = y_i^1 - y_i^0$

**Average Treatment Effect:**  $ATE = E[\tau_i] = E[y_i^1 - y_i^0] = \frac{1}{n} \sum_{i=1}^n (y_i^1 - y_i^0)$

**Conditional Average Treatment Effect:**  $CATE = E_{x_i \in X}[\tau_i]$

# 因果推断&智能营销

## 传统模型VS因果推断

相关性

≠

因果性

Response Model:  $P(Y = 1 | X)$ , 用户购买概率, 有label

Uplift Model:  $\tau(X)$ , 干预对用户购买概率的影响, 无label

因果推断在营销场景的应用主要是基于Uplift Model预测营销干预带来的增益



PART 03

## 第三部分 因果推断：Uplift建模

- 建模方法

# 因果推断：Uplift建模

Uplift

$$\tau(x) = P(y | x, t = 1) - P(y | x, t = 0)$$

Uplift模型就是学习给定一个干预（发券）后，结果（转化率）的增量，即对因果效应进行建模。

# 因果推断：Uplift建模

Uplift建模方法：meta learner

T-Learner

$$\begin{aligned} u_0 &= f(X_0, Y_0) \\ u_1 &= f(X_1, Y_1) \\ \tau(x) &= u_1(x) - u_0(x) \end{aligned}$$

S-Learner

$$\begin{aligned} u &= f(X, T, Y) \\ \tau &= u(x, T = 1) - u(x, T = 0) \end{aligned}$$

X-Learner

$$\begin{aligned} u_0 &= f(X_0, Y_0), \quad u_1 = f(X_1, Y_1) \\ D_0 &= u_1(X_0) - Y_0, \quad D_1 = Y_1 - u_0(X_1) \\ \tau_0 &= f(X_0, D_0), \quad \tau_1 = f(X_1, D_1) \\ e(x) &= P(T = 1 \mid X = x) \\ \tau(x) &= e(x)\tau_0(x) + (1 - e(x))\tau_1(x) \end{aligned}$$

R-Learner  
Tree-based Learner  
...

# 因果推断：Uplift建模

Uplift建模方法：tree model

Uplift-Tree

$$gain(A) = D(P^T(Y) : P^C(Y) | A) - D(P^T(Y) : P^C(Y))$$

$$D(P^T(Y) : P^C(Y) | A) = \sum_a \frac{N(a)}{N} D(P^T(Y|a) : P^C(Y|a))$$

$$D(P : Q) = KL(P : Q) = \sum_i p_i \log \frac{p_i}{q_i}$$

$$\tau(x) = \frac{1}{N^T | x \in l} \sum_{i|x \in l} Y_i - \frac{1}{N^C | x \in l} \sum_{i|x \in l} Y_i$$

Propensity-Tree

估计  $P(T|x)$ , 使叶子节点中的样本的propensity score一致

$$\tau(x) = \frac{1}{N^T | x \in l} \sum_{i|x \in l} Y_i - \frac{1}{N^C | x \in l} \sum_{i|x \in l} Y_i$$

Causal Forest  
Double-Sample Tree


...



# 因果推断：Uplift建模

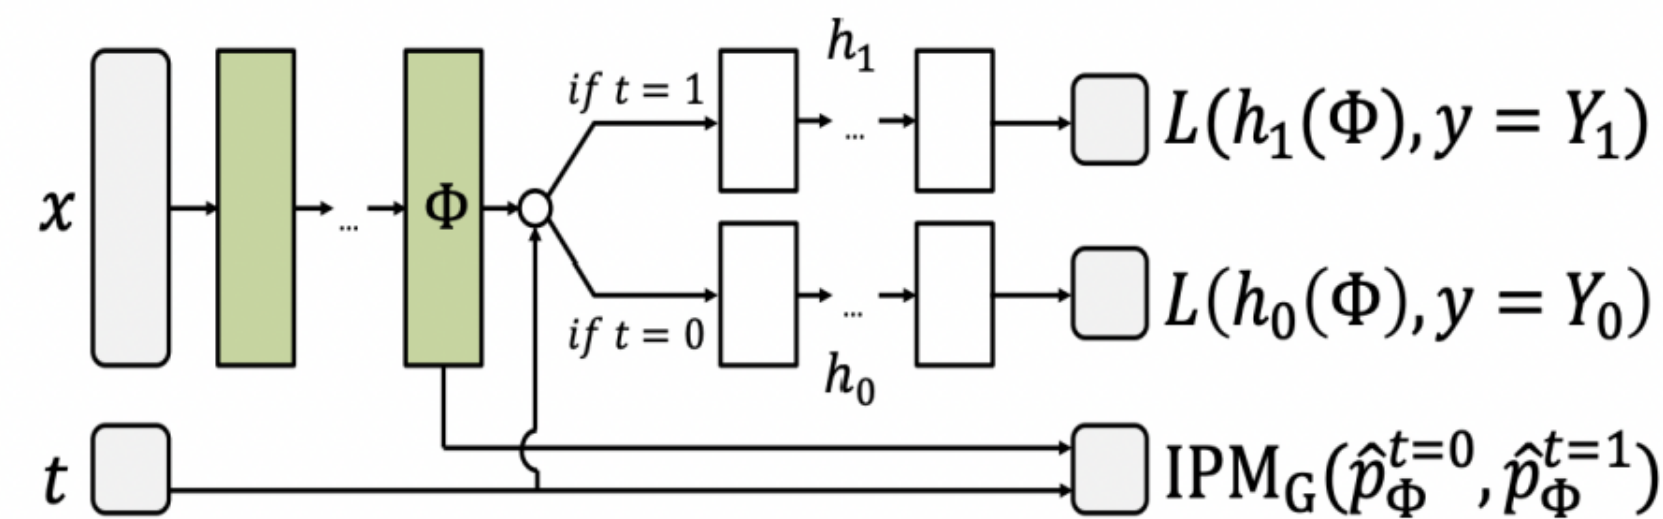
**Uplift建模方法：deep learning**      通过表征网络来解决unobserved confounder的问题，使事实分布和反事实分布一致

BNN




$$B_{\mathcal{H}, \alpha, \gamma}(\Phi, h) = \frac{1}{n} \sum_{i=1}^n |h(\Phi(x_i), t_i) - y_i^F| +$$
$$\alpha \text{disc}_{\mathcal{H}}(\hat{P}_{\Phi}^F, \hat{P}_{\Phi}^{CF}) + \frac{\gamma}{n} \sum_{i=1}^n |h(\Phi(x_i), 1 - t_i) - y_{j(i)}^F|,$$

TarNet



$$\min_{\substack{h, \Phi \\ \|\Phi\|=1}} \frac{1}{n} \sum_{i=1}^n w_i \cdot L(h(\Phi(x_i), t_i), y_i) + \lambda \cdot \mathfrak{R}(h)$$
$$+ \alpha \cdot \text{IPM}_G(\{\Phi(x_i)\}_{i:t_i=0}, \{\Phi(x_i)\}_{i:t_i=1}),$$

DragonNet



$$\hat{R}(\theta; \mathbf{X}) = \frac{1}{n} \sum_i [(Q^{\text{nn}}(t_i, x_i; \theta) - y_i)^2 + \alpha \text{CrossEntropy}(g^{\text{nn}}(x_i; \theta), t_i)],$$
$$\hat{\theta}, \hat{\varepsilon} = \underset{\theta, \varepsilon}{\operatorname{argmin}} [\hat{R}(\theta; \mathbf{X}) + \beta \frac{1}{n} \sum_i \gamma(y_i, t_i, x_i; \theta, \varepsilon)].$$



PART 04

## 第四部分

# 因果推断在哈啰的应用

- 树模型应用
- 深度模型探索



# Uplift模型在哈啰智的应用

## Uplift Tree

1. 假设分裂前数据集为 $\theta$ ，计算分裂前发券组和无券组样本人均收益的差异：

$$D(G^T : G^C) = (\frac{1}{N^T} \sum_i G^T - \frac{1}{N^C} \sum_i G^C)^2$$

2. 根据某个特征 $f$ 将数据集 $\theta$ 分成左右两个子集 $\theta_l, \theta_r$ ，计算分裂后的人均收益差异：


$$D(G^T : G^C | f) = \sum_{a \in \{\theta_l, \theta_r\}} \frac{N(a)}{N} D(G^T(a) : G^C(a))$$

3. 分裂后的人均收益差异减去分裂前的人均收益差异，得到 $D_{gain}$ ：

$$D_{gain} = D(G^T : G^C | f) - D(G^T : G^C)$$


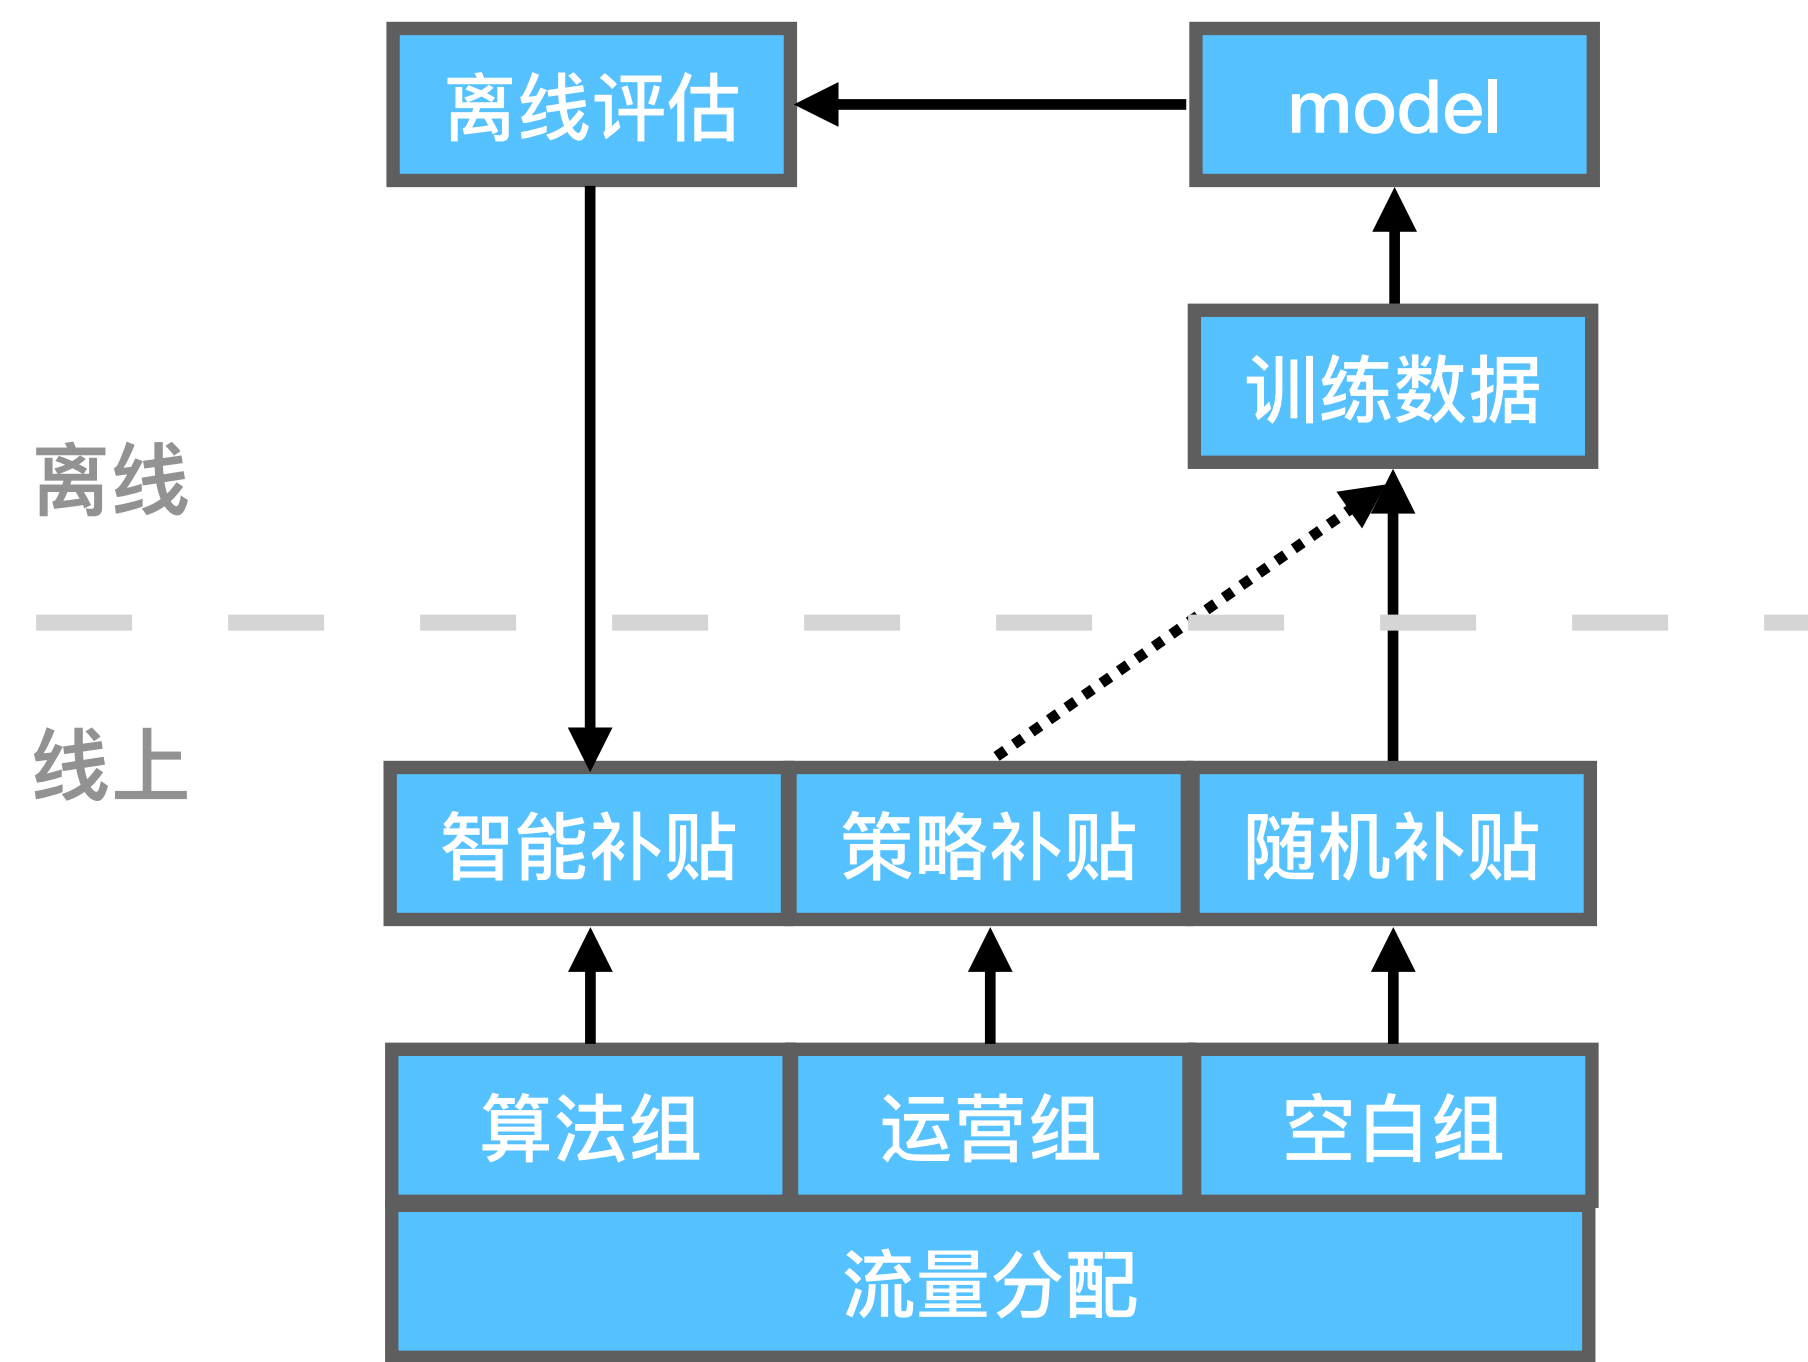
4. 遍历数据集 $\theta$ 中所有特征值，重复2、3步，取 $D_{gain}$ 最大时对应的特征值作为节点分裂值，将数据集分为 $\theta_l, \theta_r$ 。

5. 对数据集 $\theta_l, \theta_r$ 分别重复上述步骤，生成树。



# Uplift模型在哈啰智的应用

## Uplift Tree



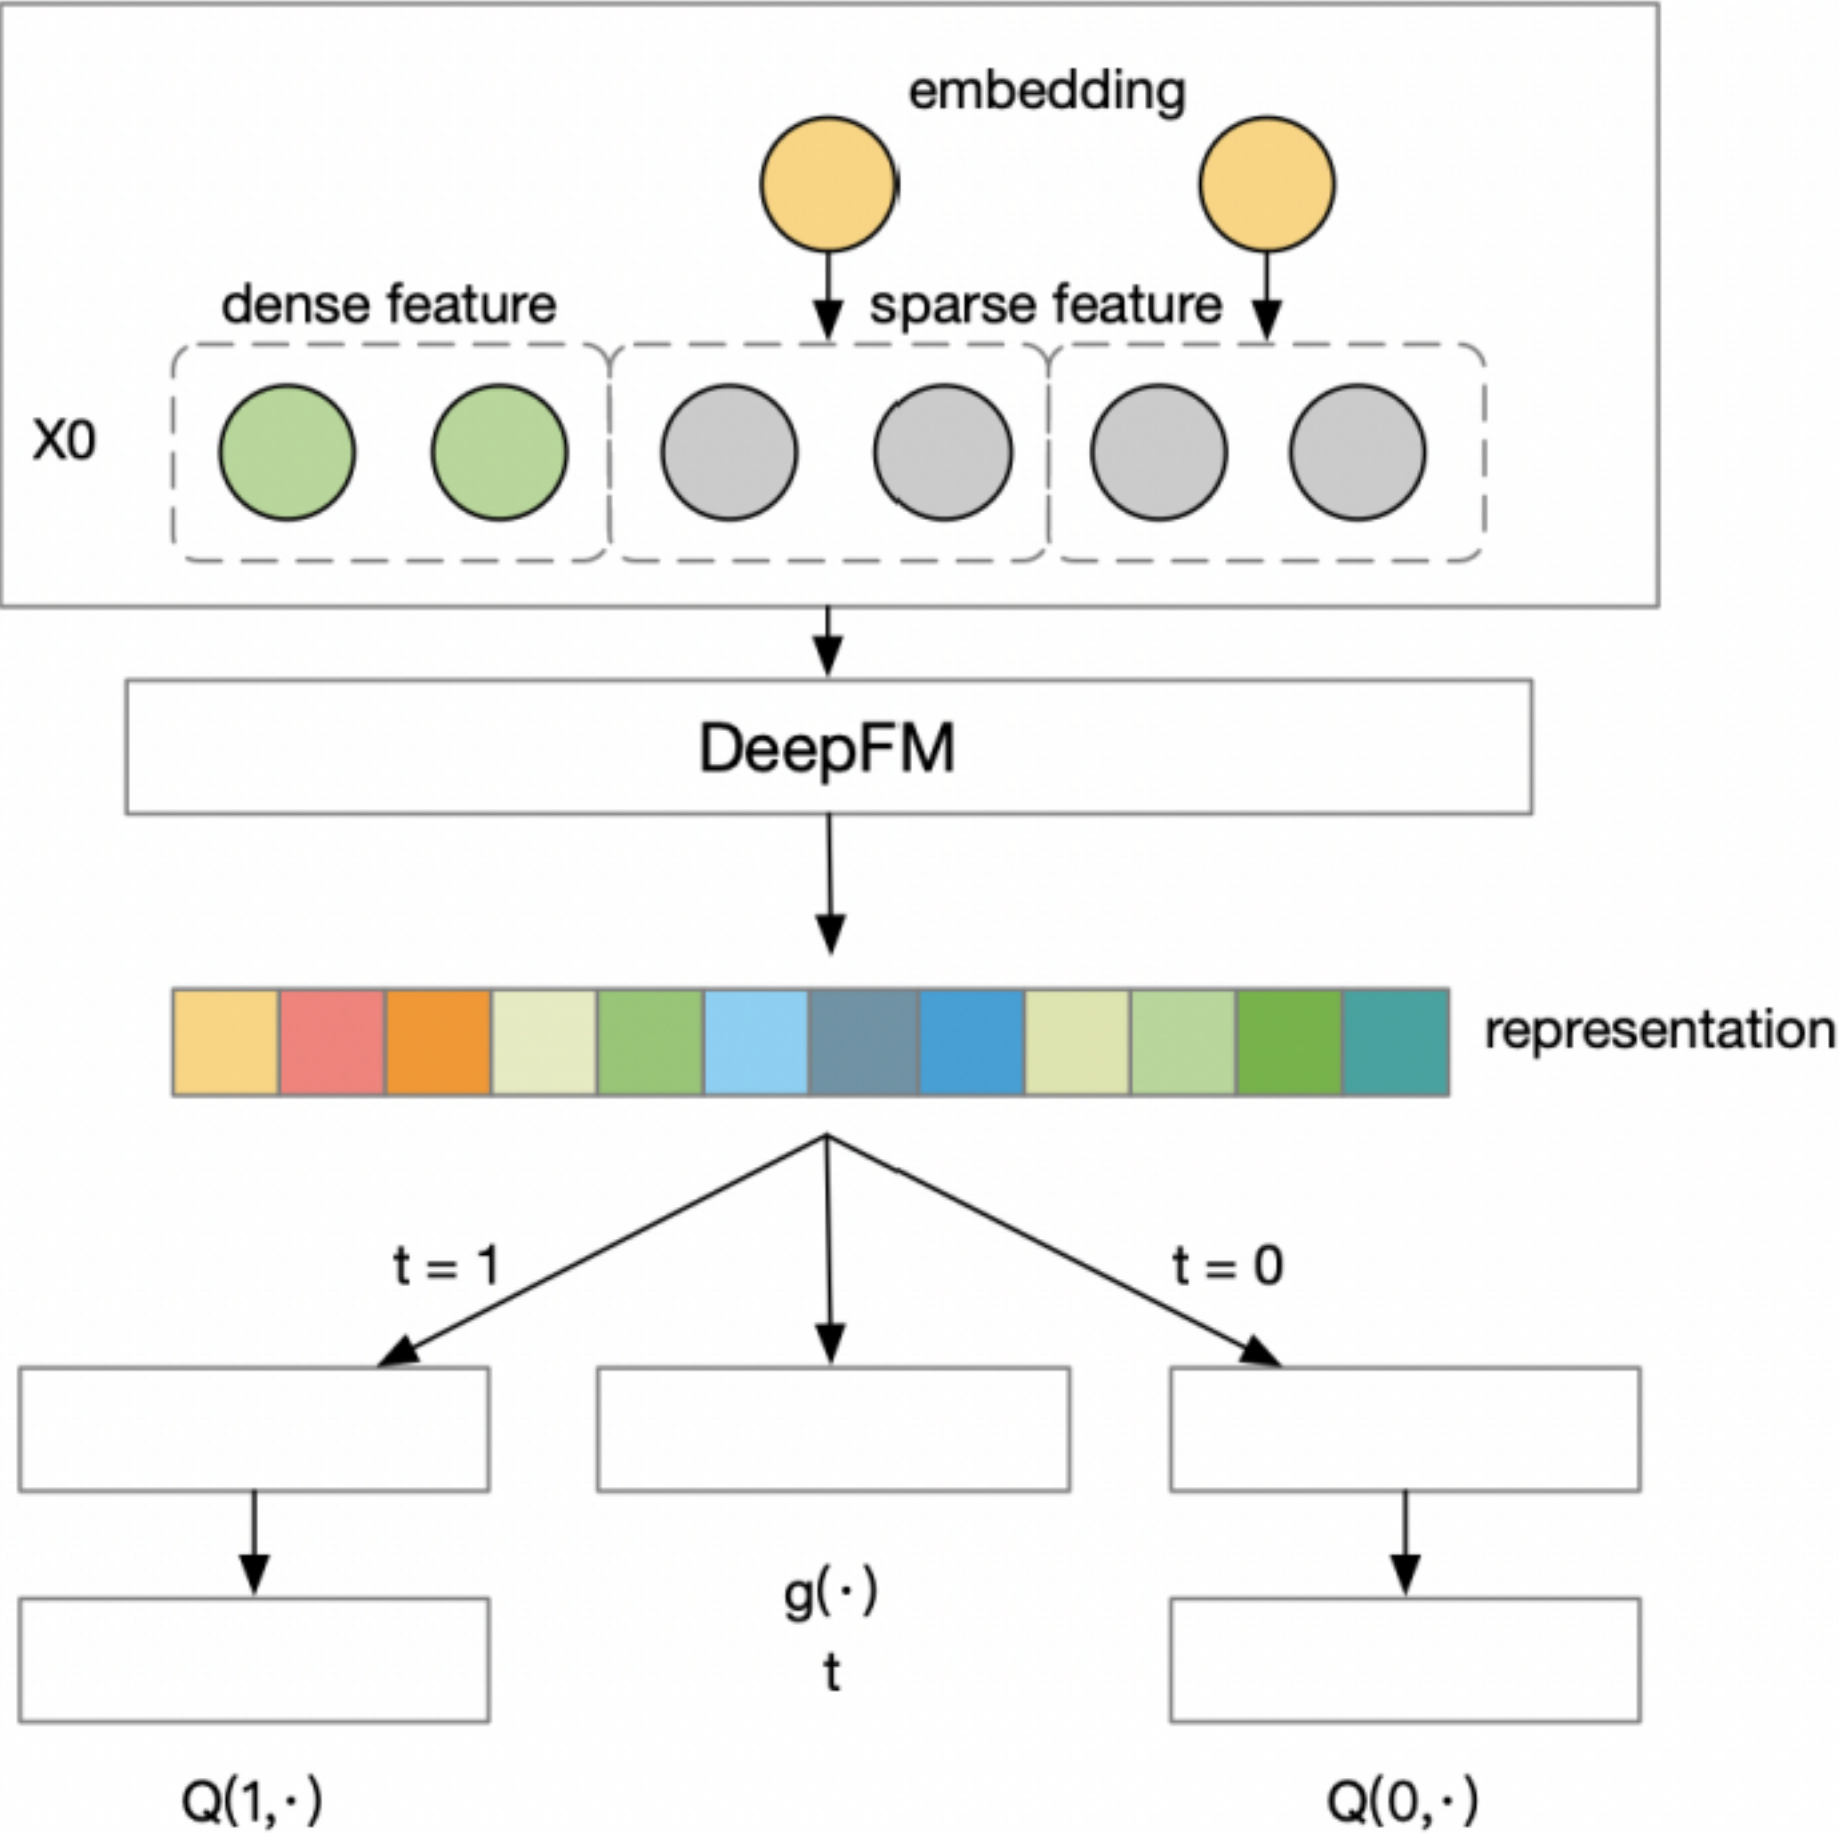
模型离线对比，uplift tree最优

分流	人均收益	实验组提升幅度
实验组	xx	-
Response Model	xx	2.3%
策略组	xx	4.7%

线上AB测试结果，uplift tree最优

# Uplift模型在哈啰智的应用

## DragonNet



$$\hat{R}(\theta; X) = \frac{1}{n} \sum_i [(Q^{\text{nn}}(t_i, x_i; \theta) - y_i)^2 + \alpha \text{CrossEntropy}(g^{\text{nn}}(x_i; \theta), t_i)],$$

$$\hat{\theta}, \hat{\varepsilon} = \underset{\theta, \varepsilon}{\operatorname{argmin}} [\hat{R}(\theta; X) + \beta \frac{1}{n} \sum_i \gamma(y_i, t_i, x_i; \theta, \varepsilon)].$$



哈啰技术

微信扫描二维码，关注我的公众号

»» THANKS ««  
Q&A





## 评估方法

反事实

无增量标签


离线: AUUC  
线上: AB对照



AUC  
准确率  
RMSE

$$f(t) = \left( \frac{Y_t^T}{N_t^T} - \frac{Y_t^C}{N_t^C} \right) (N_t^T + N_t^C)$$

$$AUUC = \sum_{t=0}^N f(t)$$



## AUUC计算流程

1. 测试集进入模型输出uplift score
2. 所有样本按照uplift score降序排序
3. 分桶, 桶序号记为 $t$
4. uplift curve:  $f(t) = \left( \frac{Y_t^T}{N_t^T} - \frac{Y_t^C}{N_t^C} \right) (N_t^T + N_t^C)$ ,  
 $Y$ 表示分组正例数量,  $N$ 表示分组总量,  
+ ∴  $.^T$ 表示Treatment组,  $.^C$ 表示Control组。
5.  $AUUC = \sum_{t=0}^N f(t)$