

面板数据因果推断

第6讲 潜因子模型

徐轶青

斯坦福大学

潜在因子模型

与合成控制法的联系

- ADH (2010) 在合成控制法中使用因子增强模型 (factor-augmented model) :

$$Y_{it}(0) = \theta_t' Z_i + \xi_t + \lambda_i' f_t + \varepsilon_{it}$$

与合成控制法的联系

- ADH (2010) 在合成控制法中使用因子增强模型 (factor-augmented model) :

$$Y_{it}(0) = \theta_t' Z_i + \xi_t + \lambda_i' f_t + \varepsilon_{it}$$

- 如果仅使用控制组个体来估计模型会怎样?

与合成控制法的联系

- ADH (2010) 在合成控制法中使用因子增强模型 (factor-augmented model) :

$$Y_{it}(0) = \theta_t' Z_i + \xi_t + \lambda_i' f_t + \varepsilon_{it}$$

- 如果仅使用在控制条件下的观测值来估计模型会怎样?
- Xu (2017) 将交互式固定效应 (IFE) 模型引入 DiD:

$$Y_{it}(0) = X_{it}' \beta + \alpha_i + \xi_t + \lambda_i' f_t + \varepsilon_{it}$$

与合成控制法的联系

- ADH (2010) 在合成控制法中使用因子增强模型 (factor-augmented model) :

$$Y_{it}(0) = \theta_t' Z_i + \xi_t + \lambda_i' f_t + \varepsilon_{it}$$

- 如果仅使用在控制条件下的观测值来估计模型会怎样?
- Xu (2017) 将交互式固定效应 (IFE) 模型引入 DiD:

$$Y_{it}(0) = X_{it}' \beta + \alpha_i + \xi_t + \lambda_i' f_t + \varepsilon_{it}$$

- Athey 等(2021) 对它进行扩展并引入矩阵补全 (matrix completion) 方法
- Liu、Wang 和 Xu (2021) 将这些方法置于“反事实估计量”的一般框架中

与合成控制法的联系

- ADH (2010) 在合成控制法中使用因子增强模型 (factor-augmented model) :

$$Y_{it}(0) = \theta_t' Z_i + \xi_t + \lambda_i' f_t + \varepsilon_{it}$$

- 如果仅使用在控制条件下的观测值来估计模型会怎样?
- Xu (2017) 将交互式固定效应 (IFE) 模型引入 DiD:

$$Y_{it}(0) = X_{it}' \beta + \alpha_i + \xi_t + \lambda_i' f_t + \varepsilon_{it}$$

- Athey 等(2021) 对它进行扩展并引入矩阵补全 (matrix completion) 方法
- Liu、Wang 和 Xu (2021) 将这些方法置于“反事实估计量 (Counterfactual estimator)”的一般框架中
- 不允许负权重!

与合成控制法的联系

- ADH (2010) 在合成控制法中使用因子增强模型 (factor-augmented model) :

$$Y_{it}(0) = \theta_t' Z_i + \xi_t + \lambda_i' f_t + \varepsilon_{it}$$

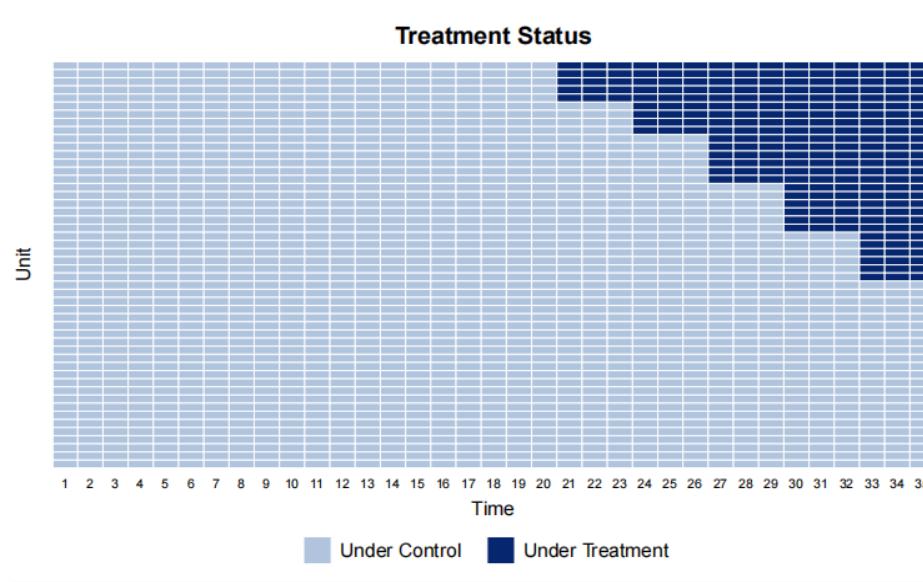
- 如果仅使用在控制条件下的观测值来估计模型会怎样?
- Xu (2017) 将交互式固定效应 (IFE) 模型引入 DiD:

$$Y_{it}(0) = X_{it}' \beta + \alpha_i + \xi_t + \lambda_i' f_t + \varepsilon_{it}$$

- Athey 等(2021) 对它进行扩展并引入矩阵补全 (matrix completion) 方法
- Liu、Wang 和 Xu (2021) 将这些方法置于“反事实估计量”的一般框架中
- 不允许负权重!
- 局限：面板数据要求大T和大N；模型依赖

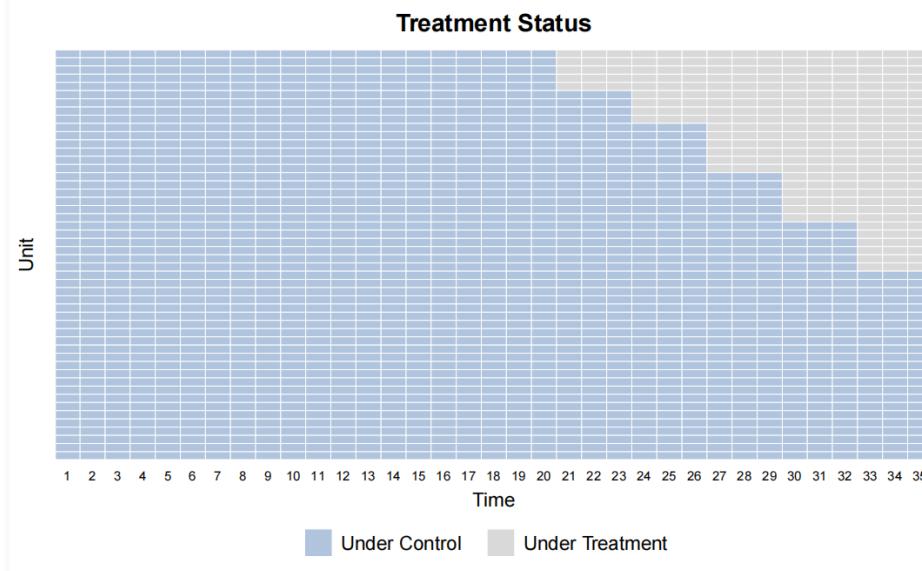
基本思路

- 在面板数据中，将 $Y(1)$ 当作缺失数据



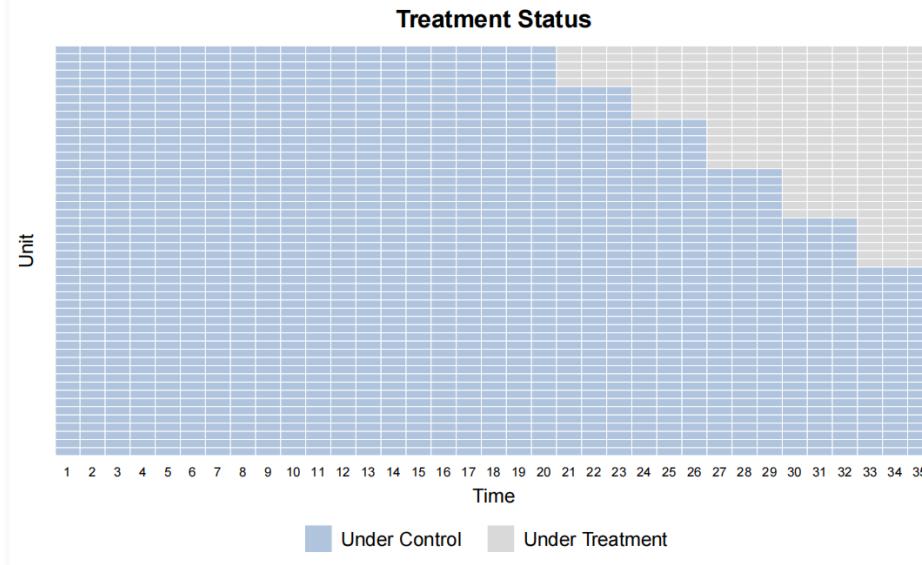
基本思路

- 在面板数据中，将 $Y(1)$ 当作缺失数据



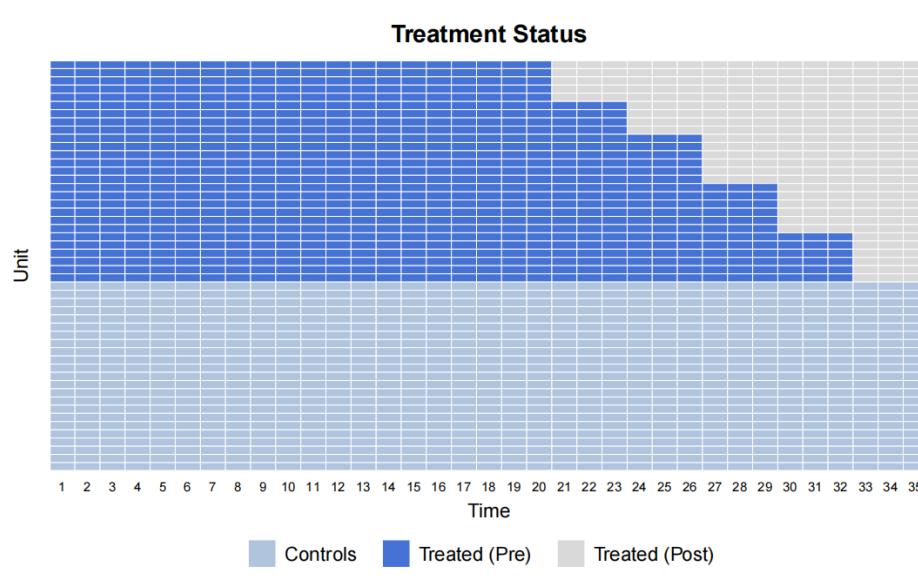
基本思路

- 在面板数据中，将 $Y(1)$ 当作缺失数据
- 基于结果模型（outcome model）预测 $Y(0)$
- （使用干预前数据来估计模型）



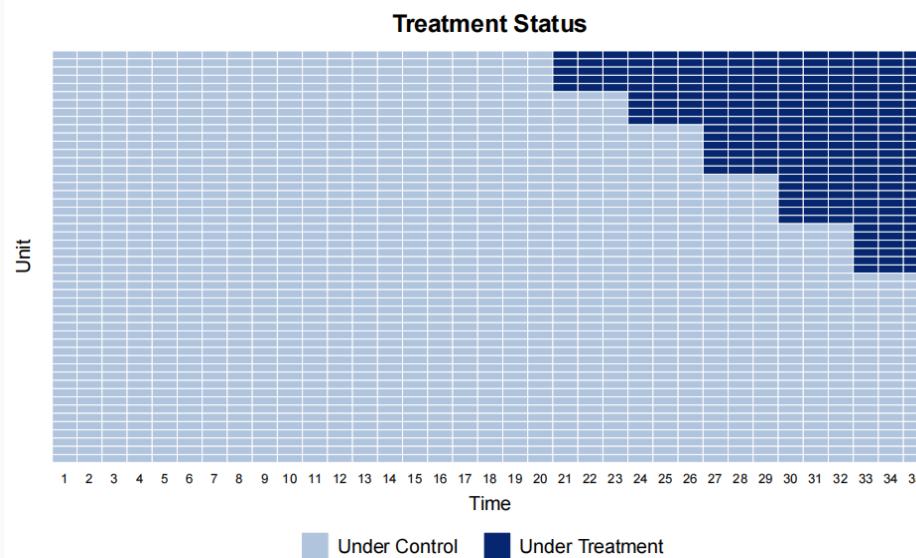
基本思路

- 在面板数据中，将 $Y(1)$ 当作缺失数据
- 基于结果模型（outcome model）预测 $Y(0)$
- （使用干预前数据来估计模型）



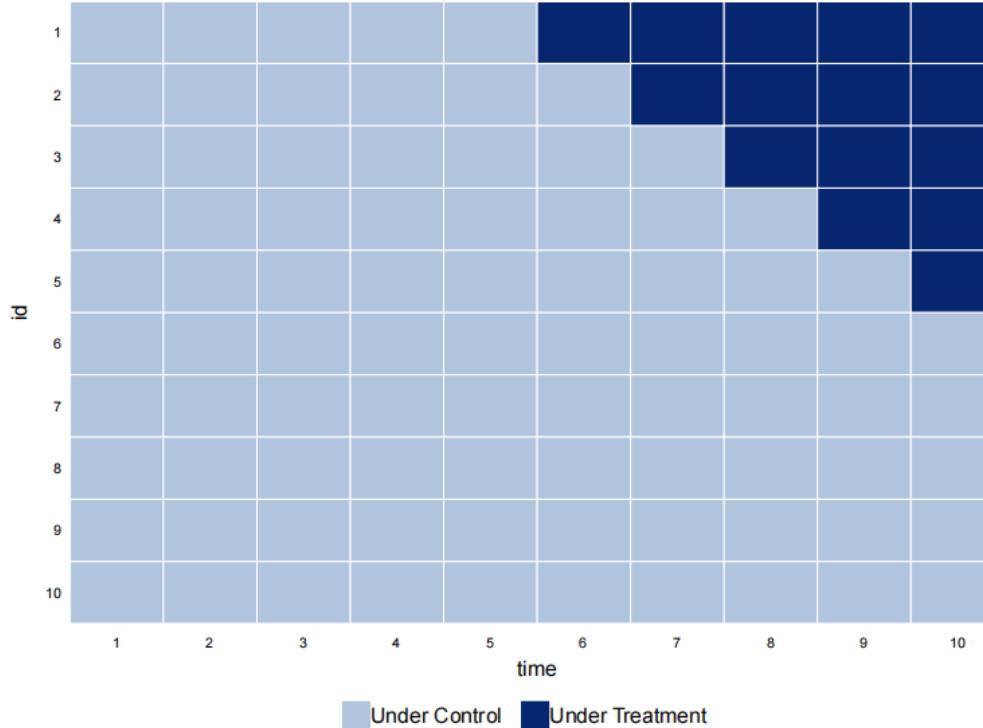
基本思路

- 在面板数据中，将 $Y(1)$ 当作缺失数据
 - 基于**结果模型** (**outcome model**) 预测 $Y(0)$
 - (使用干预前数据来估计模型)
 - 通过 $Y(1)$ 和 $\hat{Y}(0)$ 之间的平均差异来估计 ATT



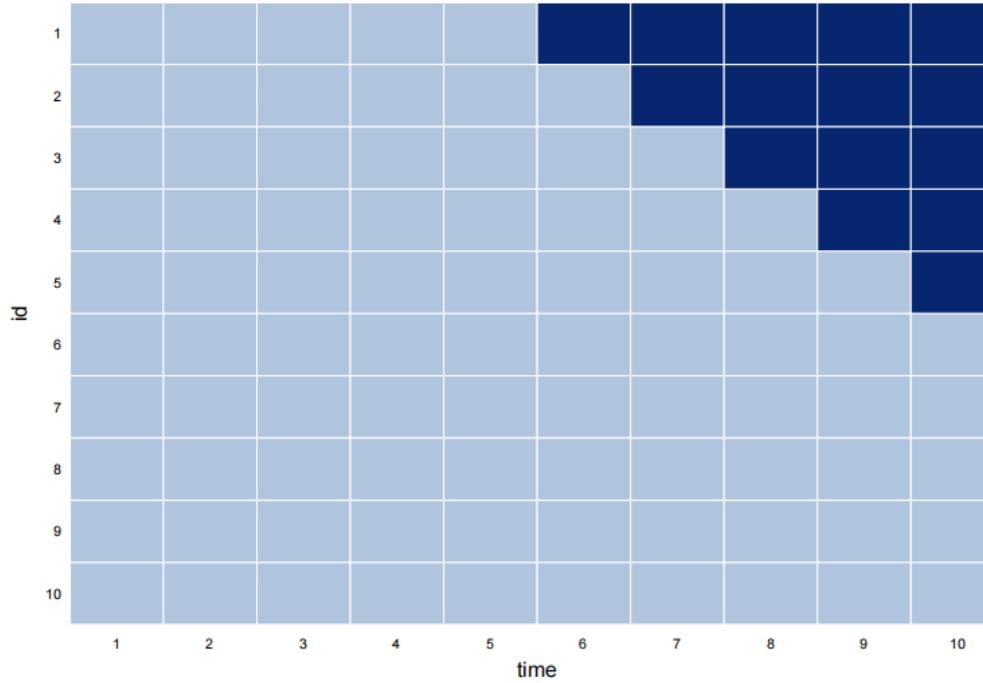
基本思路

$$\widehat{ATT} = \hat{\mathbb{E}}[\hat{\tau}_{it} | D_{it} = 1, \forall i \in \mathcal{T}, \forall t]$$



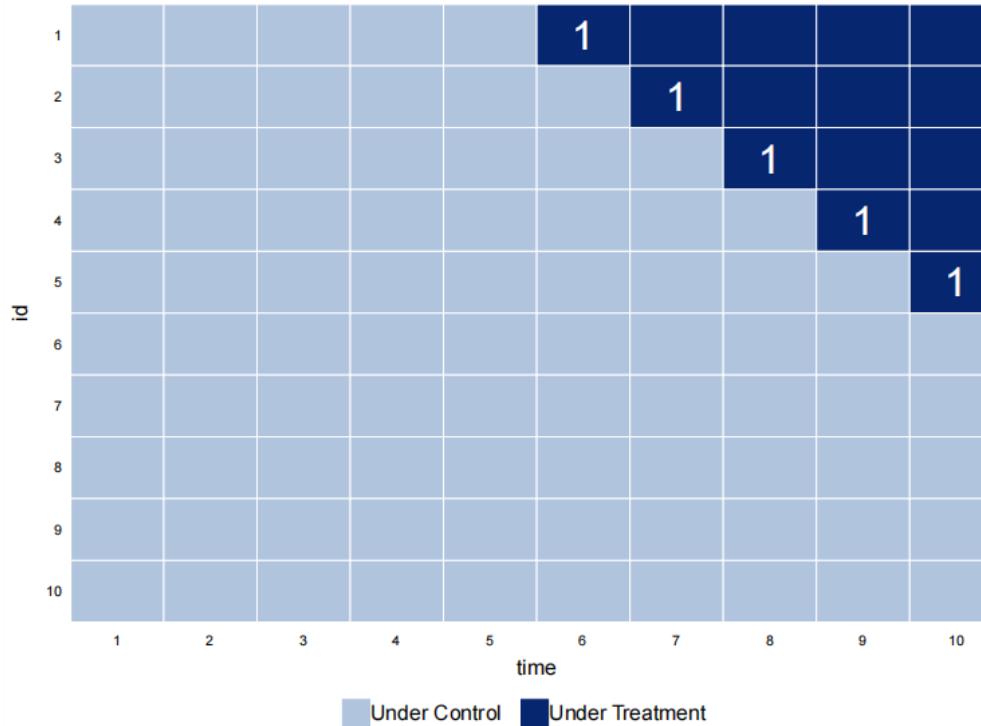
基本思路

$$\widehat{ATT}_s = \hat{\mathbb{E}}[\hat{\tau}_{it} | D_{i,t-s} = 0, \underbrace{D_{i,t-s+1} = D_{i,t-s+2} = \dots = D_{it} = 1}_{s \text{ periods}}, \forall i \in \mathcal{T}].$$



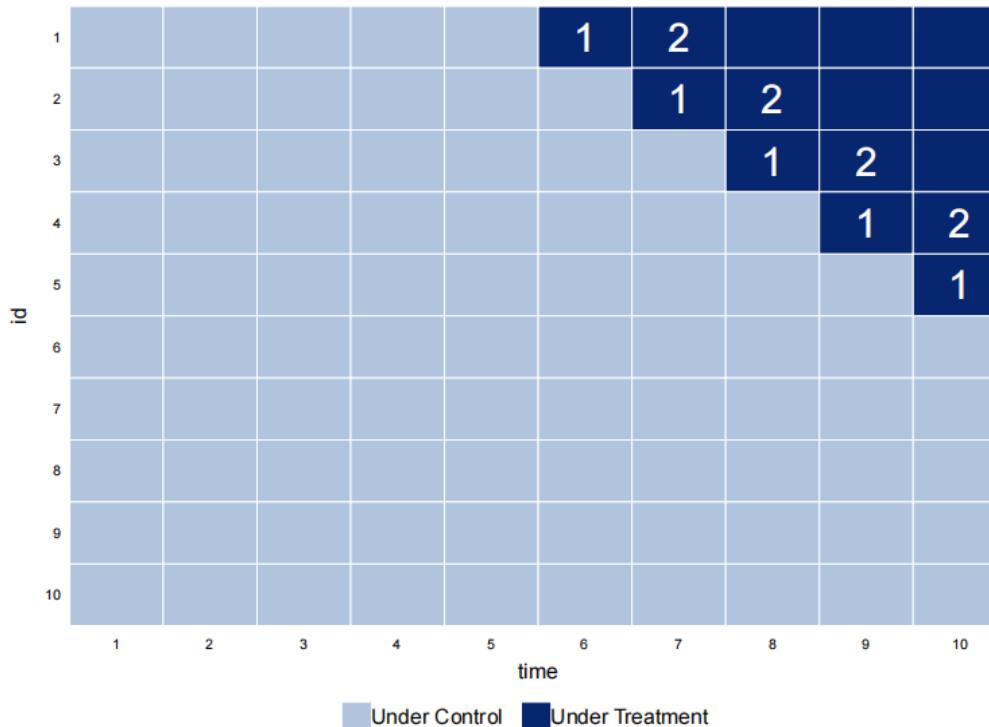
基本思路

$$\widehat{ATT}_s = \hat{\mathbb{E}}[\hat{\tau}_{it} | D_{i,t-s} = 0, \underbrace{D_{i,t-s+1} = D_{i,t-s+2} = \dots = D_{it} = 1}_{s \text{ periods}}, \forall i \in \mathcal{T}].$$



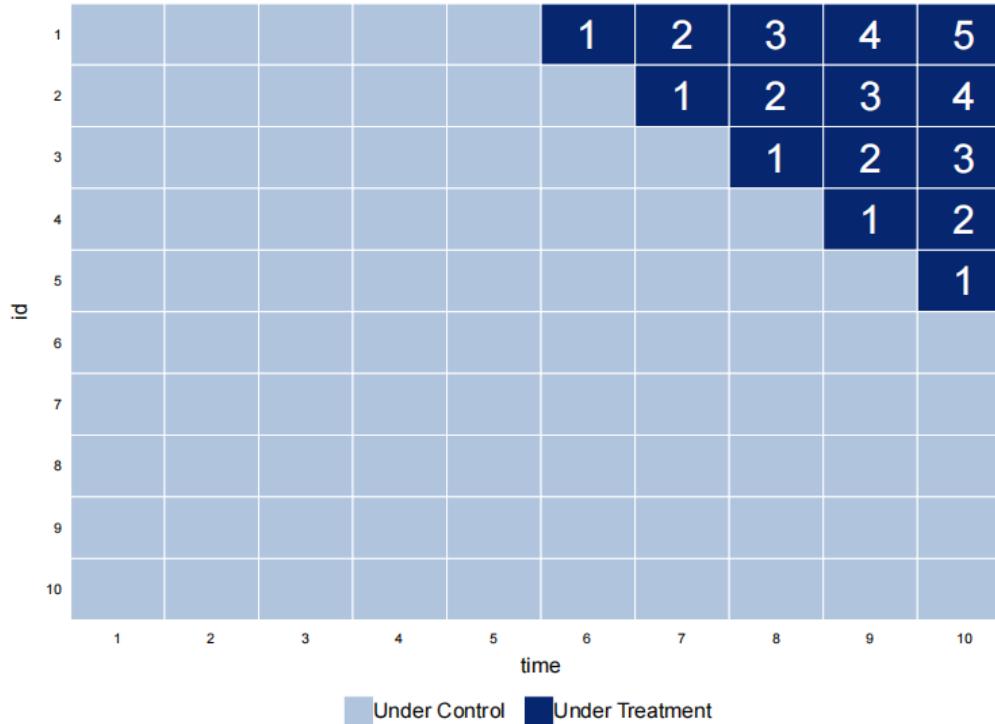
基本思路

$$\widehat{ATT}_s = \hat{\mathbb{E}}[\hat{\tau}_{it} | D_{i,t-s} = 0, \underbrace{D_{i,t-s+1} = D_{i,t-s+2} = \dots = D_{it} = 1}_{s \text{ periods}}, \forall i \in \mathcal{T}].$$



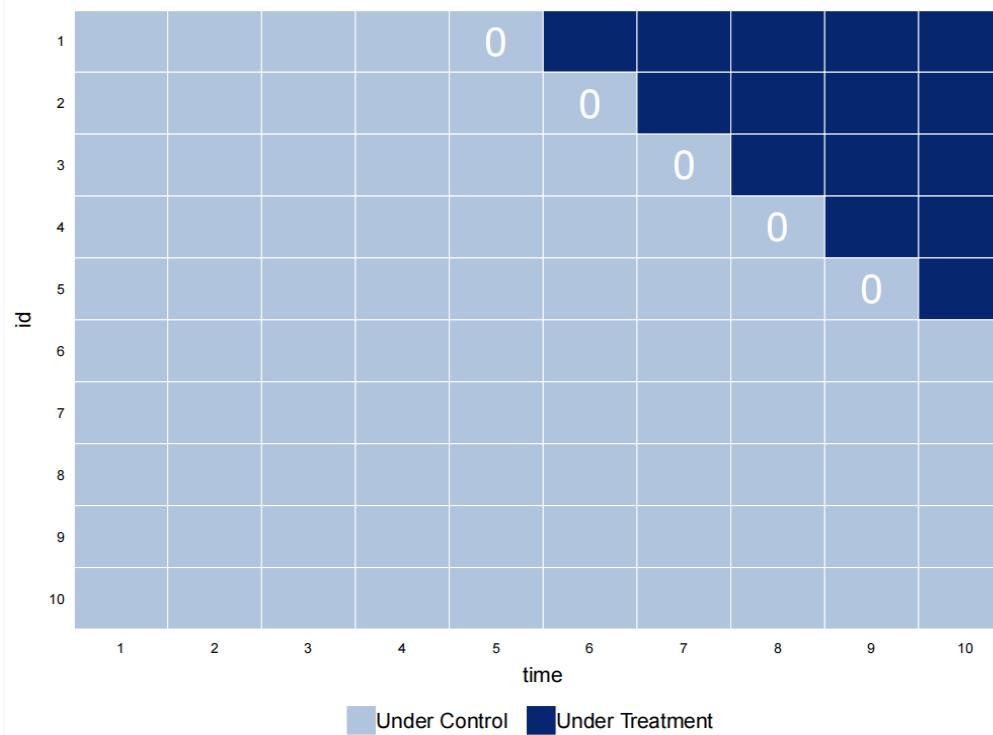
基本思路

$$\widehat{ATT}_s = \hat{\mathbb{E}}[\hat{\tau}_{it} | D_{i,t-s} = 0, \underbrace{D_{i,t-s+1} = D_{i,t-s+2} = \dots = D_{it} = 1}_{s \text{ periods}}, \forall i \in \mathcal{T}].$$



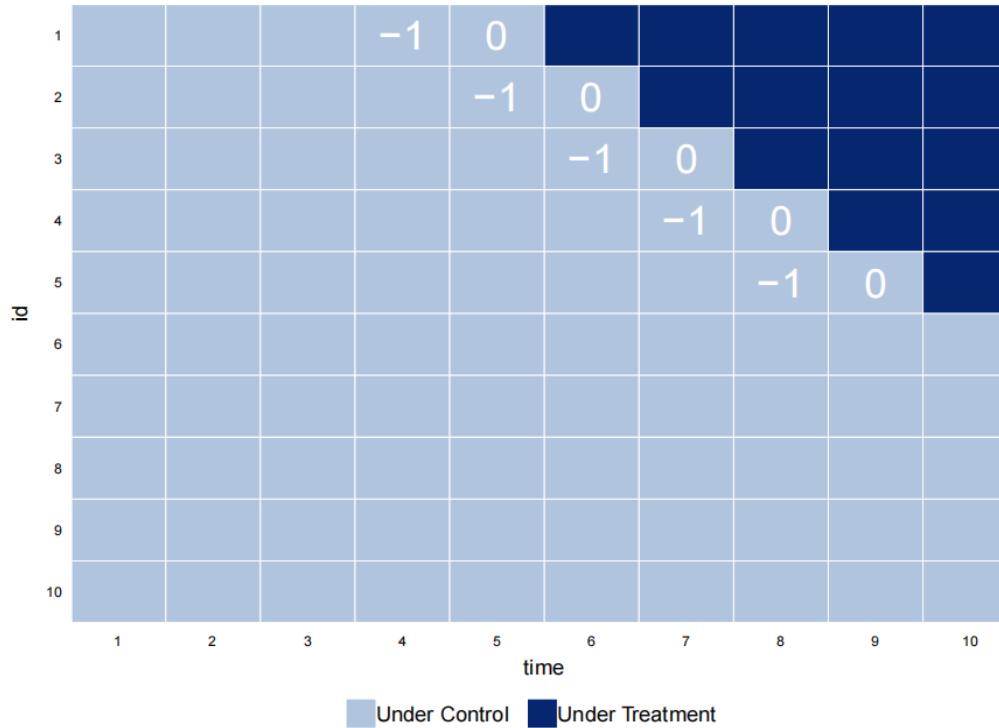
基本思路

$$\widehat{ATT}_s = \hat{\mathbb{E}}[\hat{\tau}_{it} | D_{i,t-s} = 0, \underbrace{D_{i,t-s+1} = D_{i,t-s+2} = \dots = D_{it} = 1}_{s \text{ periods}}, \forall i \in \mathcal{T}].$$



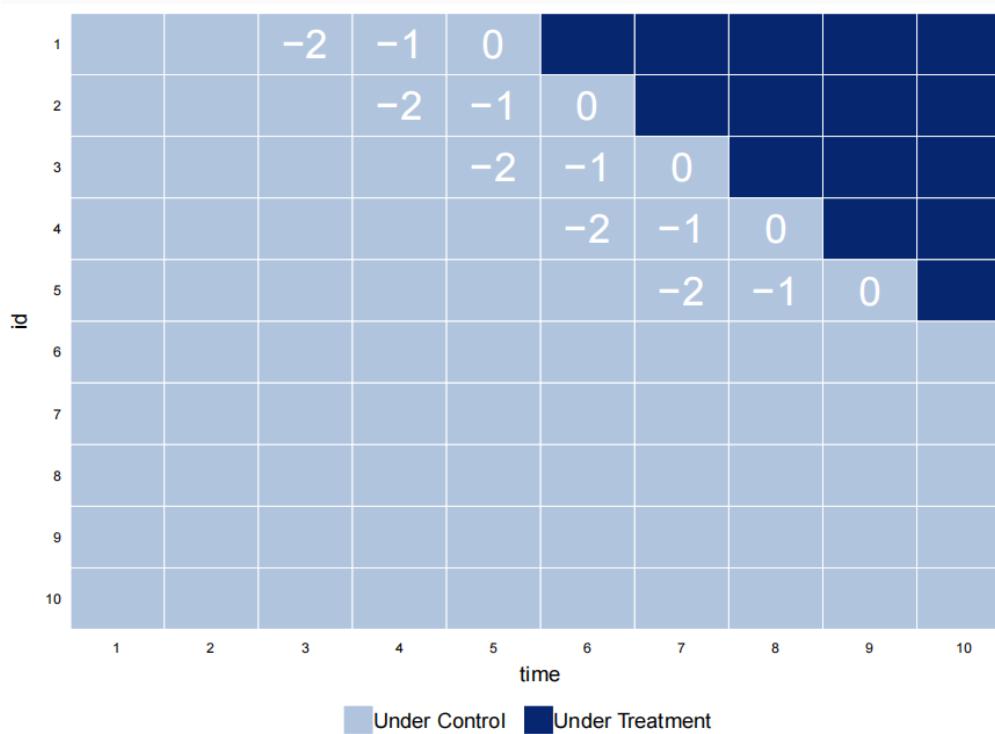
基本思路

$$\widehat{ATT}_s = \hat{\mathbb{E}}[\hat{\tau}_{it} | D_{i,t-s} = 0, \underbrace{D_{i,t-s+1} = D_{i,t-s+2} = \dots = D_{it} = 1}_{s \text{ periods}}, \forall i \in \mathcal{T}].$$



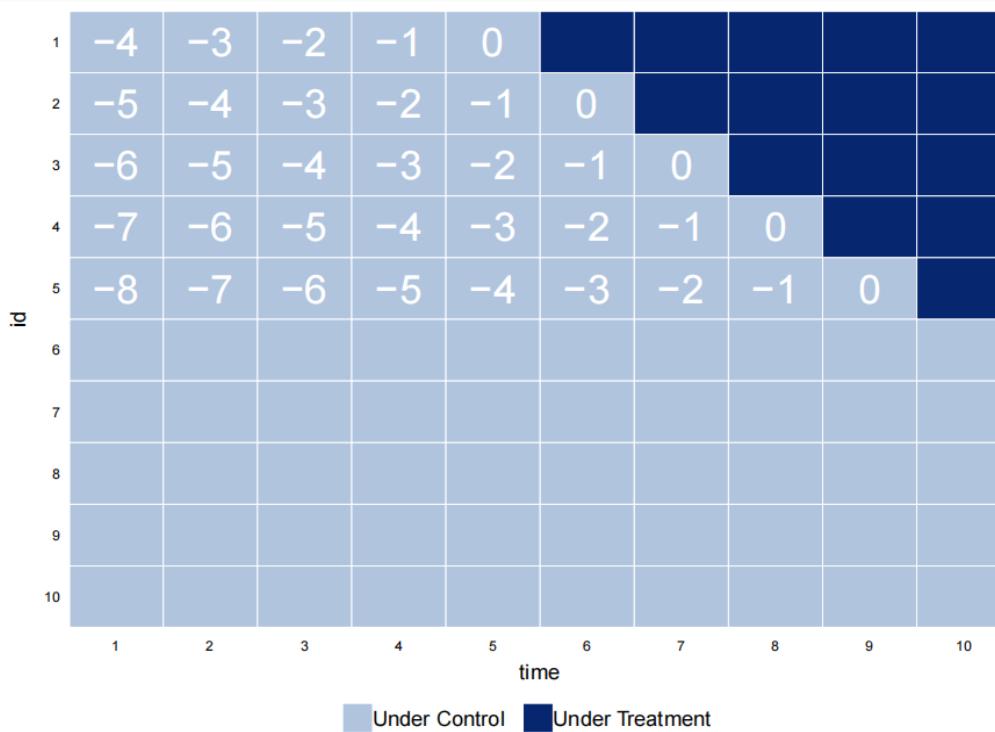
基本思路

$$\widehat{ATT}_s = \hat{\mathbb{E}}[\hat{\tau}_{it} | D_{i,t-s} = 0, \underbrace{D_{i,t-s+1} = D_{i,t-s+2} = \dots = D_{it} = 1}_{s \text{ periods}}, \forall i \in \mathcal{T}].$$



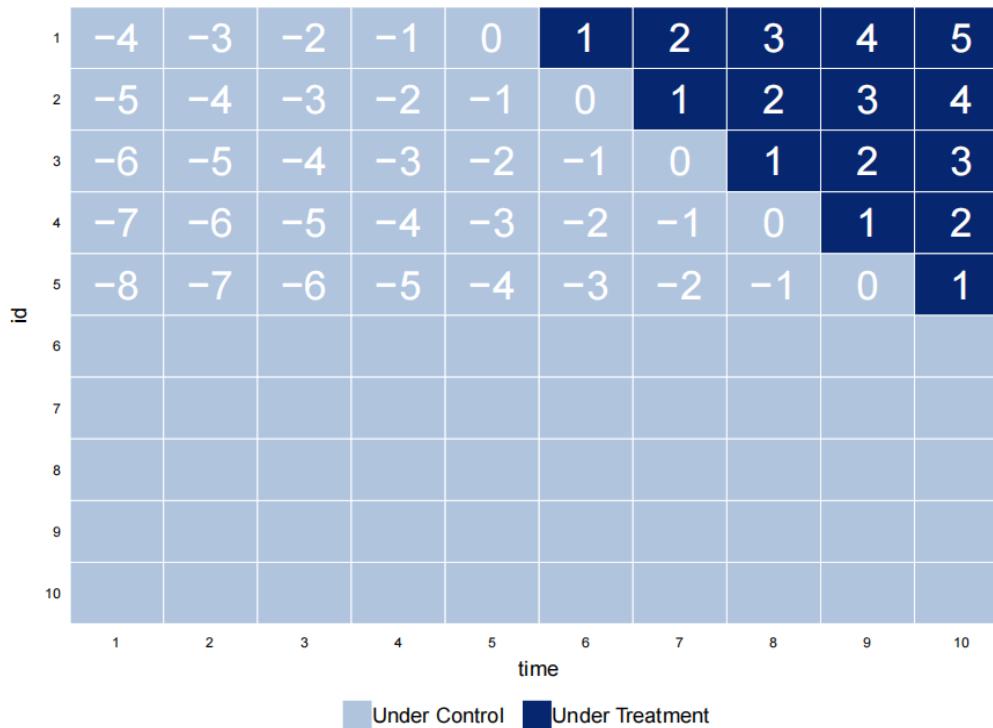
基本思路

$$\widehat{ATT}_s = \hat{\mathbb{E}}[\hat{\tau}_{it} | D_{i,t-s} = 0, \underbrace{D_{i,t-s+1} = D_{i,t-s+2} = \dots = D_{it} = 1}_{s \text{ periods}}, \forall i \in \mathcal{T}].$$

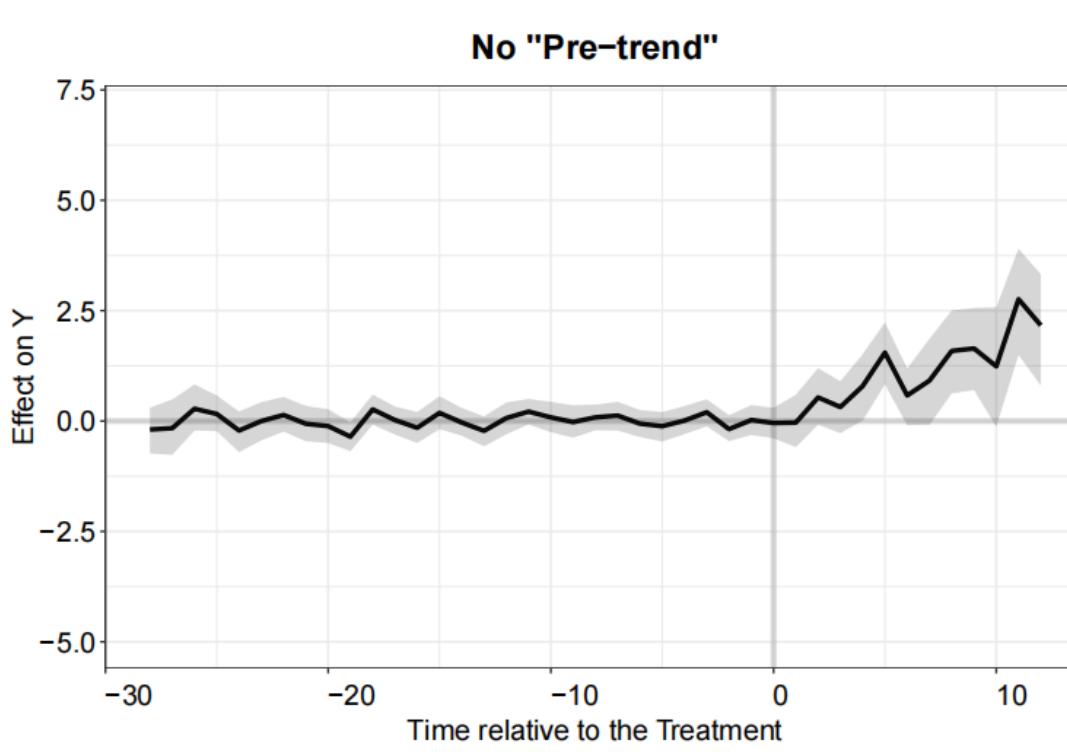


基本思路

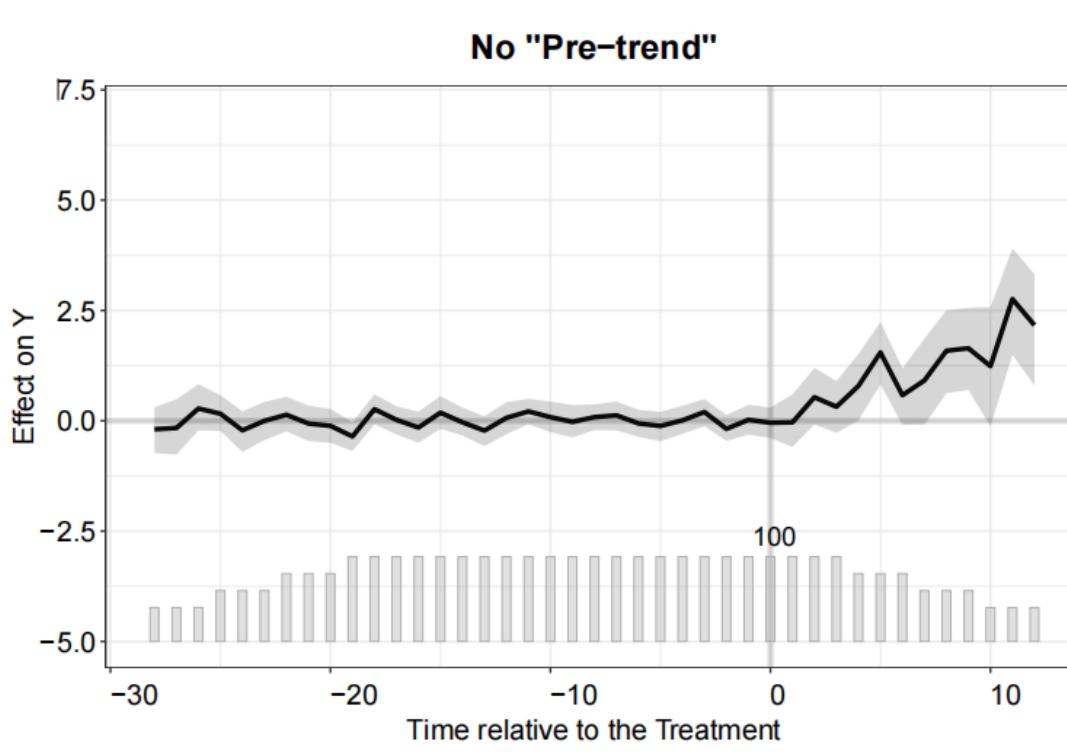
$$\widehat{ATT}_s = \hat{\mathbb{E}}[\hat{\tau}_{it} | D_{i,t-s} = 0, \underbrace{D_{i,t-s+1} = D_{i,t-s+2} = \dots = D_{it} = 1}_{s \text{ periods}}, \forall i \in \mathcal{T}].$$



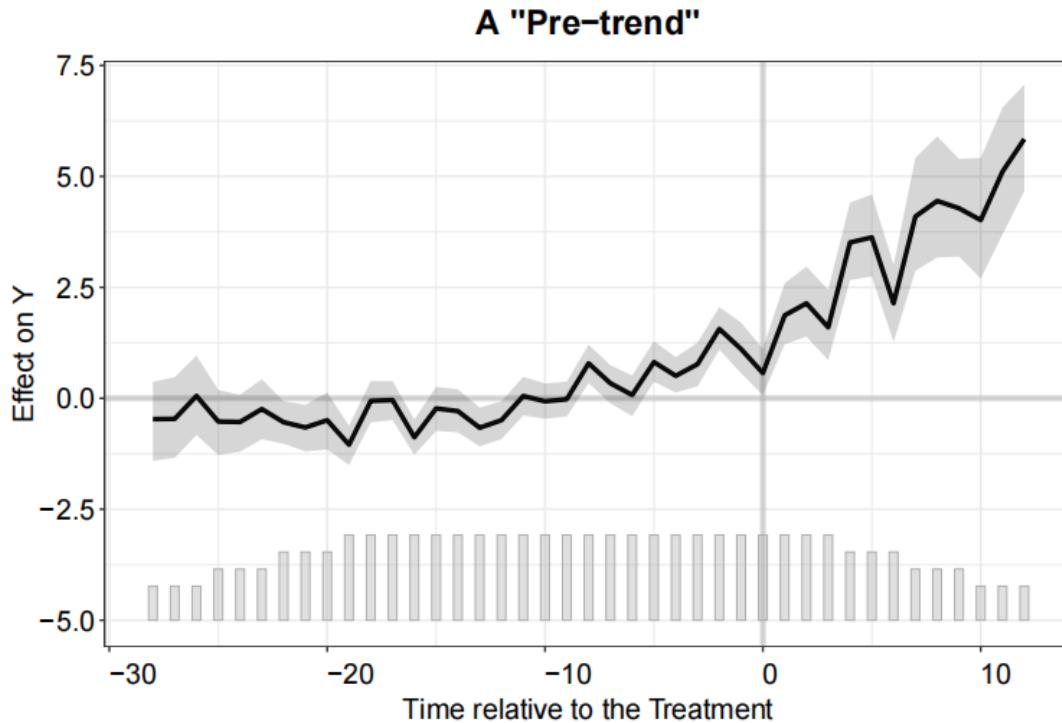
“动态处置效应”的新图像



“动态处置效应”的新图像



“动态处置效应”的新图像



当前实践：Angrist & Pischke 第 5 章

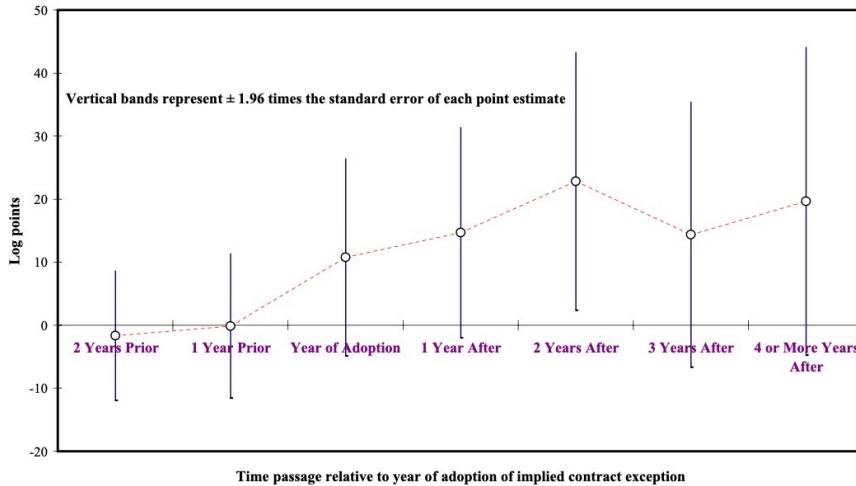


Figure 5.2.4: Estimated impact of state courts' adoption of an implied-contract exception to the employment-at-will doctrine on use of temporary workers (from Autor 2003). The dependent variable is the log of state temporary help employment in 1979 - 1995. Estimates are from a model that allows for effects before, during, and after adoption.

当前实践：Angrist & Pischke 第 5 章

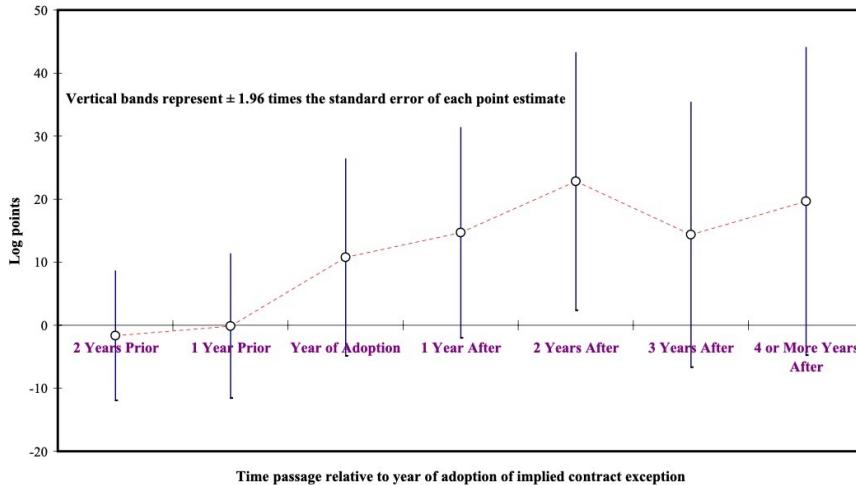


Figure 5.2.4: Estimated impact of state courts' adoption of an implied-contract exception to the employment-at-will doctrine on use of temporary workers (from Autor 2003). The dependent variable is the log of state temporary help employment in 1979 - 1995. Estimates are from a model that allows for effects before, during, and after adoption.

让我们回顾Sun & Abraham (2021)提出的批判

Stanford University

基于模型的反事实估计

基于模型的反事实估计步骤：

基于模型的反事实估计

基于模型的反事实估计步骤：

- (1) 使用控制组 ($D_{it}=0$) 的个体训练模型。

基于模型的反事实估计

基于模型的反事实估计步骤：

- (1) 使用控制组 ($D_{it}=0$) 的个体训练模型。
- (2) 预测干预组 ($D_{it}=1$) 个体的反事实结果 $\hat{Y}(0)$, 并获得个体处理效应的估计值: $\hat{\tau}_{it} = Y_{it} - \hat{Y}_{it}(0)$

基于模型的反事实估计

基于模型的反事实估计步骤：

- (1) 使用控制组 ($D_{it}=0$) 的个体训练模型。
- (2) 预测干预组 ($D_{it}=1$) 个体的反事实结果 $\hat{Y}(0)$, 并获得个体处理效应的估计值: $\hat{\tau}_{it} = Y_{it} - \hat{Y}_{it}(0)$
- (3) 得到我们关注的因果估计量:

$$ATT = \mathbb{E}[\tau_{it}|D_{it} = 1, \forall i \in \mathcal{T}, \forall t], \quad \text{or}$$

$$ATT_s = \mathbb{E}[\tau_{it}|D_{i,t-s} = 0, \underbrace{D_{i,t-s+1} = D_{i,t-s+2} = \cdots = D_{it} = 1}_{s \text{ periods}}, \forall i \in \mathcal{T}].$$

回顾三种估计策略

- FEct:

$$\hat{Y}_{it}(0) = X_{it}\hat{\beta} + \hat{\alpha}_i + \hat{\xi}_t$$

回顾三种估计策略

- FEct:

$$\hat{Y}_{it}(0) = X_{it}\hat{\beta} + \hat{\alpha}_i + \hat{\xi}_t$$

- IFEct (Gobillon & Magnac 2016; Xu 2017):

$$\hat{Y}_{it}(0) = X_{it}\hat{\beta} + \hat{\lambda}'_i \hat{F}_t$$

回顾三种估计策略

- FEct:

$$\hat{Y}_{it}(0) = X_{it}\hat{\beta} + \hat{\alpha}_i + \hat{\xi}_t$$

- IFEct (Gobillon & Magnac 2016; Xu 2017):

$$\hat{Y}_{it}(0) = X_{it}\hat{\beta} + \hat{\lambda}'_i \hat{F}_t$$

- 矩阵补全(MC) (Athey et al. 2018):

$$\hat{Y}_{it}(0) = X_{it}\hat{\beta} + \hat{L}_{it},$$

其中，矩阵 $\{L_{it}\}_{N \times T}$ 是矩阵 $\{Y(0)\}_{N \times T}$ 的一个含缺失值的低秩矩阵近似

回顾三种估计策略

重点提要：

- DiD 是 FEct 的一个特例

回顾三种估计策略

重点提要：

- DiD 是 FEct 的一个特例
- FEct 的计算方法与 [BJS\(2021\)](#) 提出的插补估计相同

回顾三种估计策略

重点提要：

- DiD 是 FEct 的一个特例
- FEct 的计算方法与 [BJS\(2021\)](#) 提出的插补估计相同
- IFEct 和 MC 都是通过迭代算法估计的

回顾三种估计策略

重点提要：

- DiD 是 FEct 的一个特例
- FEct 的计算方法与 [BJS\(2021\)](#) 提出的插补估计相同
- IFEct 和 MC 都是通过迭代算法估计的
- 通过交叉验证来选择调整参数

IFEct

Xu (2017) 提出了基于潛在因子模型的三步法：

$$\text{Control} \quad Y_{it}(0) = X'_{it}\beta + \alpha_i + \xi_t + \lambda'_i f_t + \varepsilon_{it}$$

IFEct

Xu (2017) 提出了基于潛在因子模型的三步法：

$$\begin{array}{lll} \text{Control} & Y_{it}(0) & = X'_{it}\beta + \alpha_i + \xi_t + \lambda'_i f_t + \varepsilon_{it} \\ \text{Treated} & Y_{it}(0) & = X'_{it}\beta + \alpha_i + \xi_t + \lambda'_i f_t + \varepsilon_{it} \quad (\text{pre}) \\ & Y_{it}(1) & = X'_{it}\beta + \alpha_i + \xi_t + \lambda'_i f_t + \varepsilon_{it} + \tau_{it} \quad (\text{post}) \end{array}$$

IFEct

Xu (2017) 提出了基于潛在因子模型的三步法：

$$\begin{array}{lll} \text{Control} & Y_{it}(0) & = \lambda_i' f_t + \varepsilon_{it} \\ \text{Treated} & Y_{it}(0) & = \lambda_i' f_t + \varepsilon_{it} \quad (\text{pre}) \\ & Y_{it}(1) & = \lambda_i' f_t + \varepsilon_{it} + \tau_{it} \quad (\text{post}) \end{array}$$

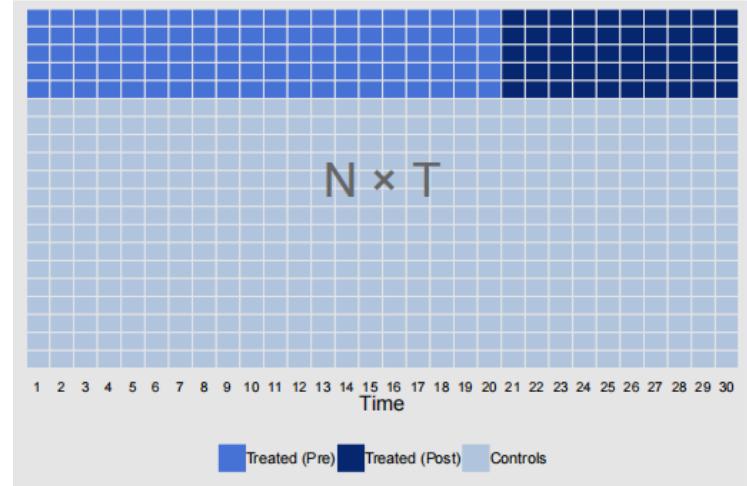
IFEct

Xu (2017) 提出了基于潛在因子模型的三步法：

$$\text{Control} \quad Y_{it}(0) = \lambda_i' f_t + \varepsilon_{it}$$

$$\text{Treated} \quad Y_{it}(0) = \lambda_i' f_t + \varepsilon_{it} \quad (\text{pre})$$

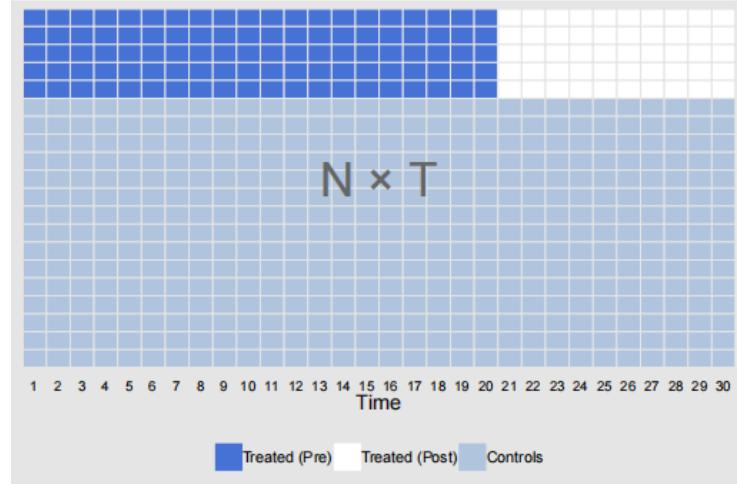
$$Y_{it}(1) = \lambda_i' f_t + \varepsilon_{it} + \tau_{it} \quad (\text{post})$$



IFEct

Xu (2017) 提出了基于潛在因子模型的三步法：

$$\begin{array}{lll} \text{Control} & Y_{it}(0) & = \lambda_i' f_t + \varepsilon_{it} \\ \text{Treated} & Y_{it}(0) & = \lambda_i' f_t + \varepsilon_{it} \quad (\text{pre}) \\ & Y_{it}(1) & = \lambda_i' f_t + \varepsilon_{it} + \tau_{it} \quad (\text{post}) \end{array}$$

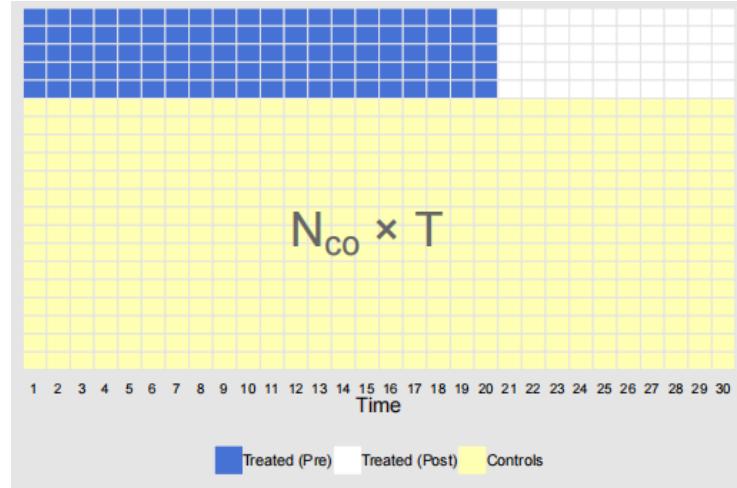


IFEct

Xu (2017) 提出了基于潛在因子模型的三步法：

$$\begin{array}{lll} \text{Control} & Y_{it}(0) & = \lambda_i' f_t + \varepsilon_{it} \\ \text{Treated} & Y_{it}(0) & = \lambda_i' f_t + \varepsilon_{it} \quad (\text{pre}) \\ & Y_{it}(1) & = \lambda_i' f_t + \varepsilon_{it} + \tau_{it} \quad (\text{post}) \end{array}$$

- 1. 利用控制组进行估计

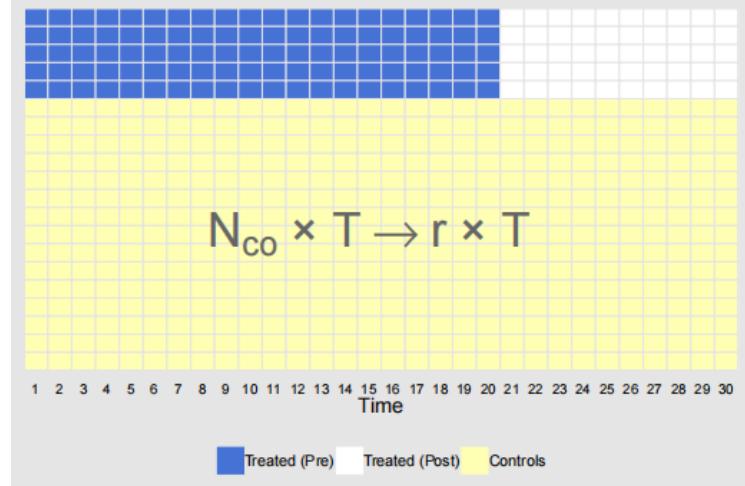


IFEct

Xu (2017) 提出了基于潛在因子模型的三步法：

$$\begin{array}{lll} \text{Control} & Y_{it}(0) & = \lambda_i' f_t + \varepsilon_{it} \\ \text{Treated} & Y_{it}(0) & = \lambda_i' f_t + \varepsilon_{it} \quad (\text{pre}) \\ & Y_{it}(1) & = \lambda_i' f_t + \varepsilon_{it} + \tau_{it} \quad (\text{post}) \end{array}$$

- 1. 利用控制组进行估计



IFEct

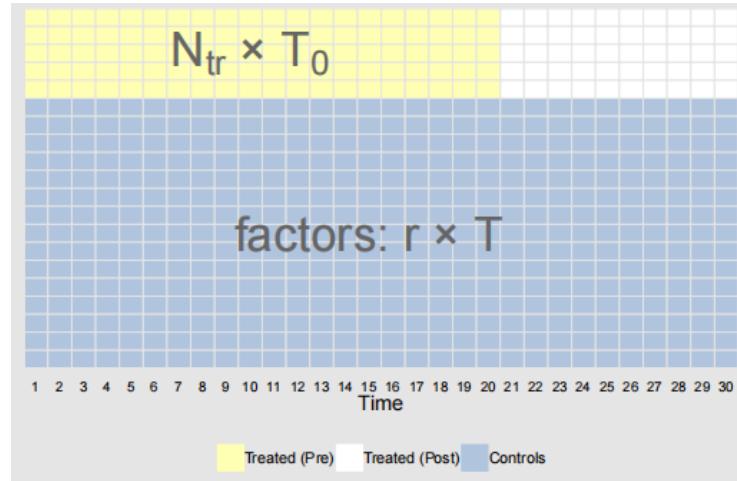
Xu (2017) 提出了基于潛在因子模型的三步法：

$$\text{Control} \quad Y_{it}(0) = \lambda_i' f_t + \varepsilon_{it}$$

$$\text{Treated} \quad Y_{it}(0) = \lambda_i' f_t + \varepsilon_{it} \quad (\text{pre})$$

$$Y_{it}(1) = \lambda_i' f_t + \varepsilon_{it} + \tau_{it} \quad (\text{post})$$

- 1. 利用控制组进行估计
- 2. 预测处理组的反事实结果 $\widehat{Y}_{it}(0)$

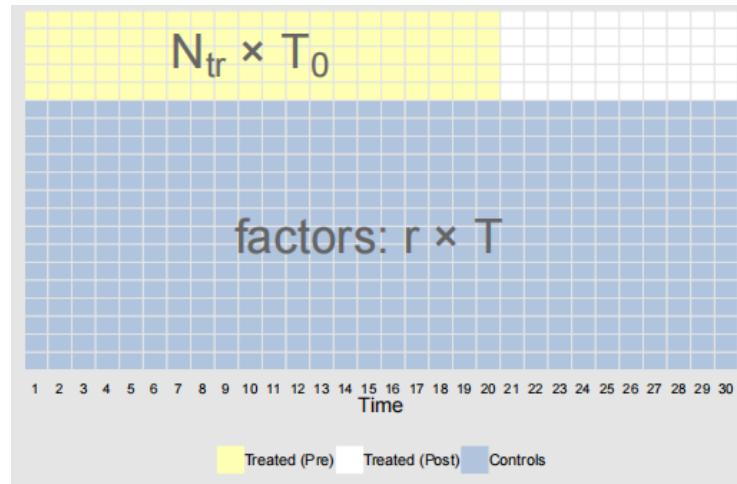


IFEct

Xu (2017) 提出了基于潛在因子模型的三步法：

$$\begin{array}{lll} \text{Control} & Y_{it}(0) & = \lambda_i' f_t + \varepsilon_{it} \\ \text{Treated} & Y_{it}(0) & = \lambda_i' f_t + \varepsilon_{it} \quad (\text{pre}) \\ & Y_{it}(1) & = \lambda_i' f_t + \varepsilon_{it} + \tau_{it} \quad (\text{post}) \end{array}$$

- 1. 利用控制组进行估计
- 2. 预测处理组的反事实结果 $\widehat{Y}_{it}(0)$
- 3. 计算ATT



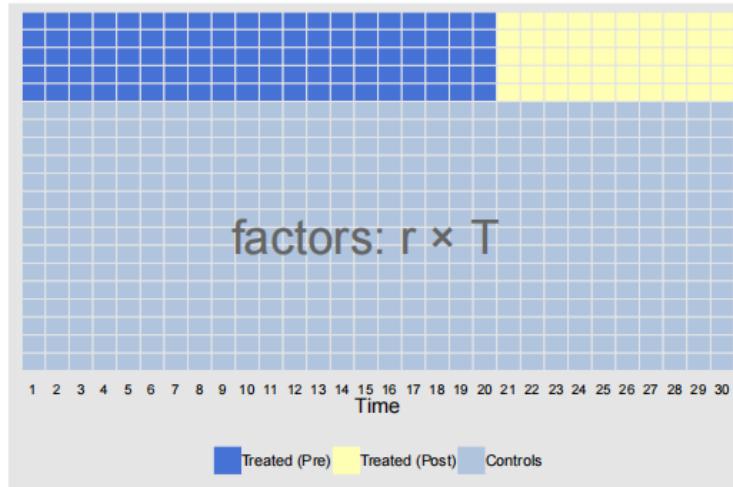
IFEct

Xu (2017) 提出了基于潛在因子模型的三步法：

$$\begin{array}{lll} \text{Control} & Y_{it}(0) & = \lambda_i' f_t + \varepsilon_{it} \\ \text{Treated} & Y_{it}(0) & = \lambda_i' f_t + \varepsilon_{it} \quad (\text{pre}) \\ & Y_{it}(1) & = \lambda_i' f_t + \varepsilon_{it} + \tau_{it} \quad (\text{post}) \end{array}$$

- 1. 利用控制组进行估计
- 2. 预测处理组的反事实结果 $\widehat{Y}_{it}(0)$
- 3. 计算ATT
- 4. 期望最大化

(Gobillon & Magnac 2016)



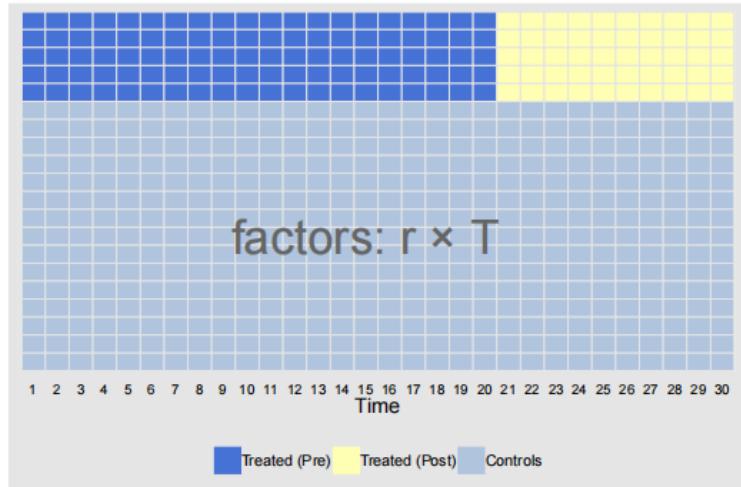
IFEct

Xu (2017) 提出了基于潛在因子模型的三步法：

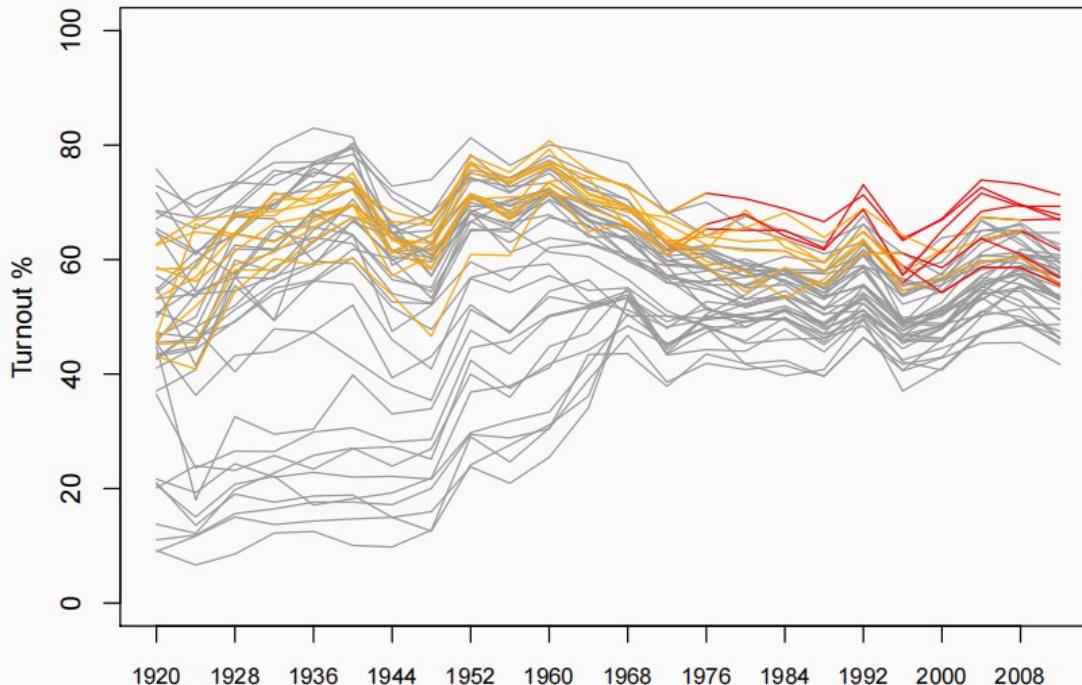
$$\begin{array}{lll} \text{Control} & Y_{it}(0) & = X'_{it}\beta + \alpha_i + \xi_t + \lambda'_i f_t + \varepsilon_{it} \\ \text{Treated} & Y_{it}(0) & = X'_{it}\beta + \alpha_i + \xi_t + \lambda'_i f_t + \varepsilon_{it} \quad (\text{pre}) \\ & Y_{it}(1) & = X'_{it}\beta + \alpha_i + \xi_t + \lambda'_i f_t + \varepsilon_{it} + \tau_{it} \quad (\text{post}) \end{array}$$

- 1. 利用控制组进行估计
- 2. 预测处理组的反事实结果 $\widehat{Y}_{it}(0)$
- 3. 计算ATT
- 4. 期望最大化

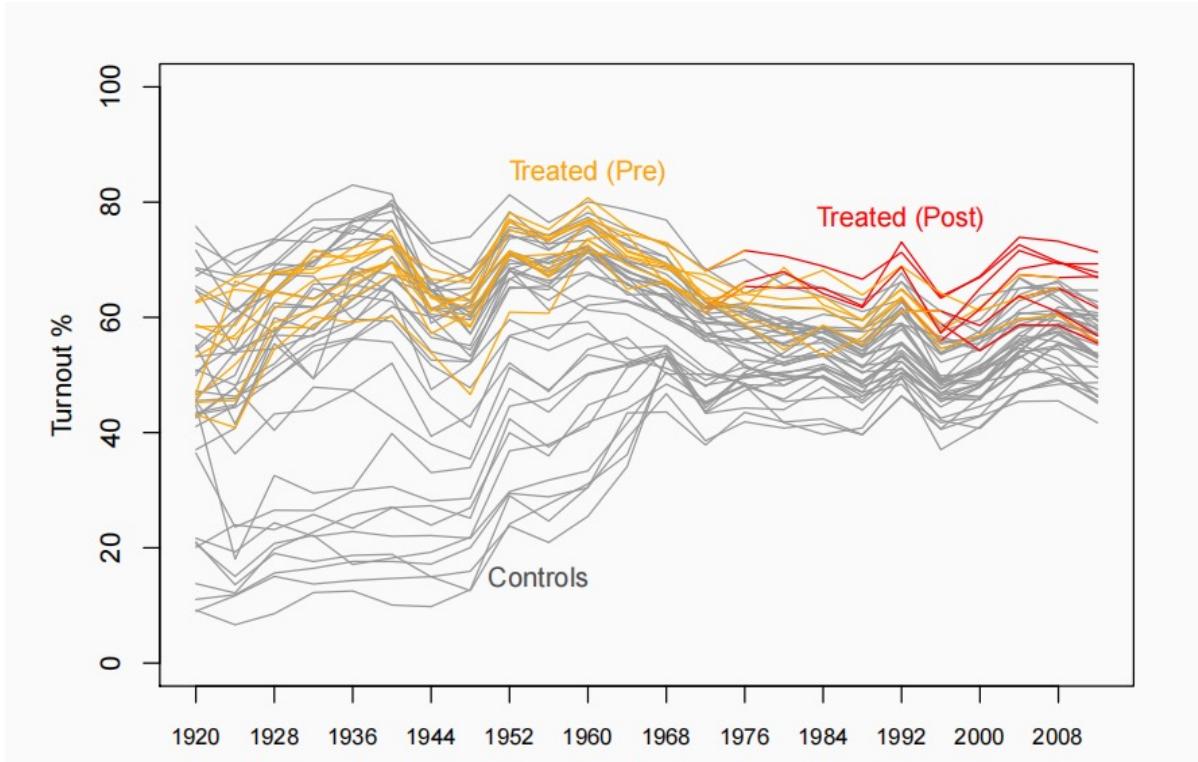
(Gobillon & Magnac 2016)



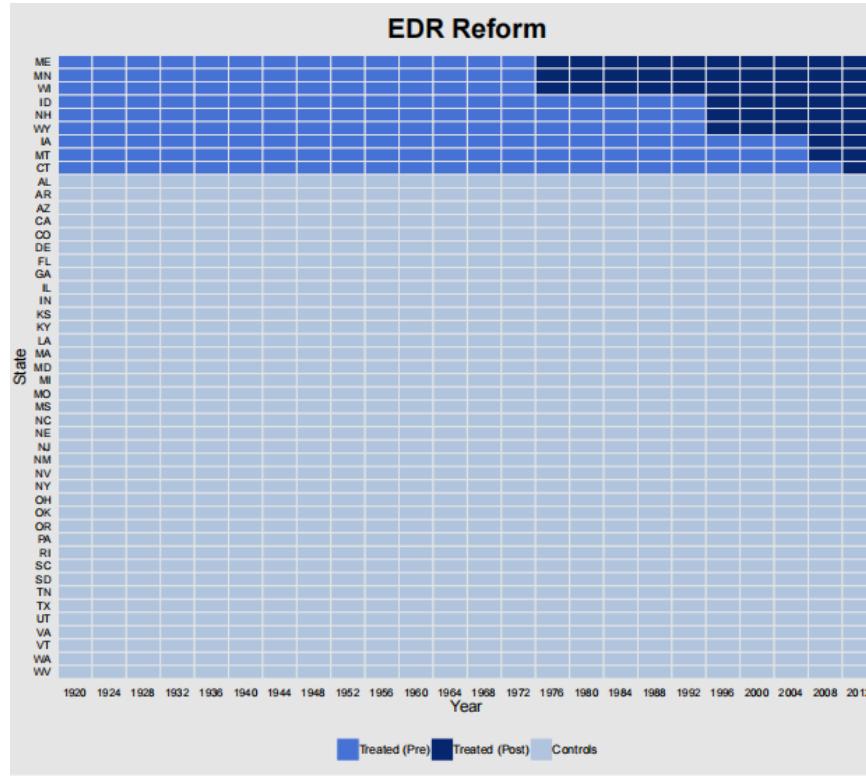
选举日登记 (EDR) 和选民投票率



选举日登记 (EDR) 和选民投票率

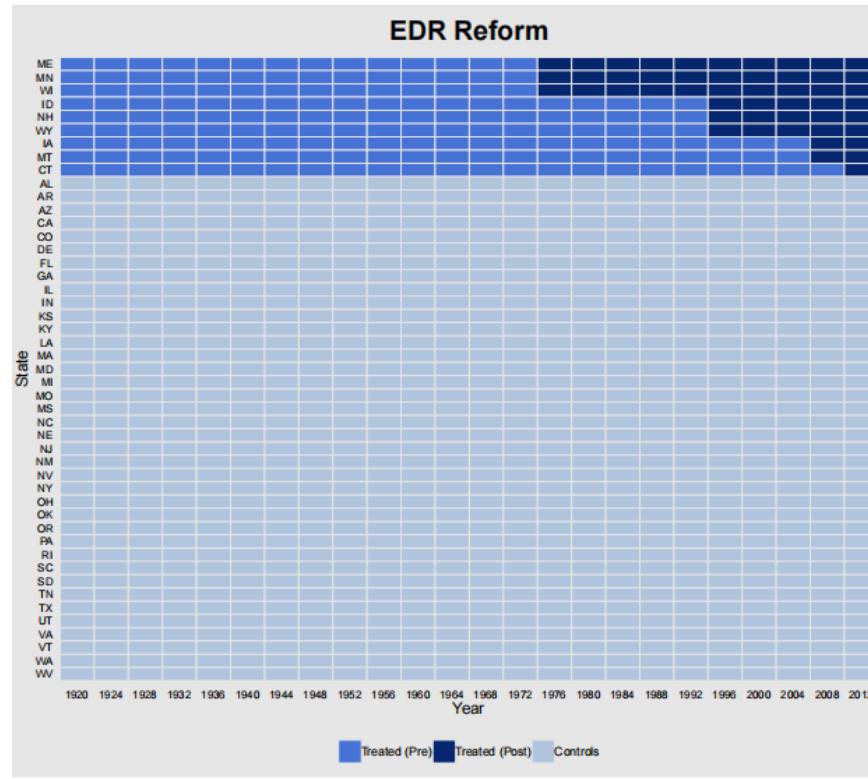


选举日登记 (EDR) 和选民投票率

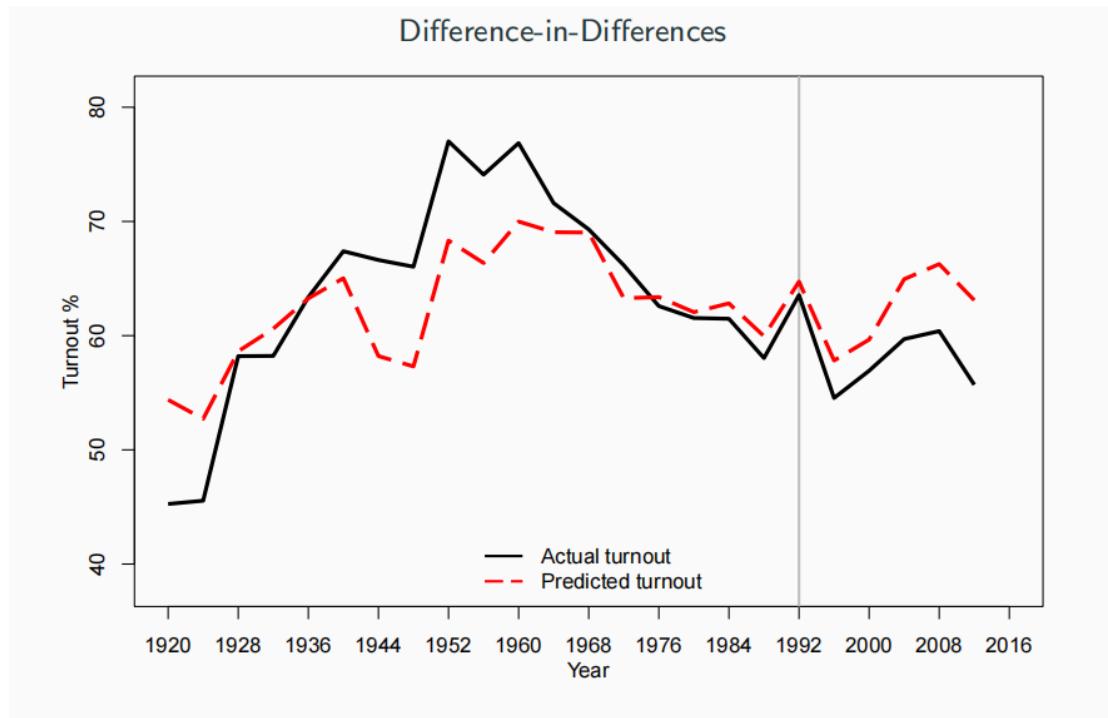


选举日登记 (EDR) 和选民投票率

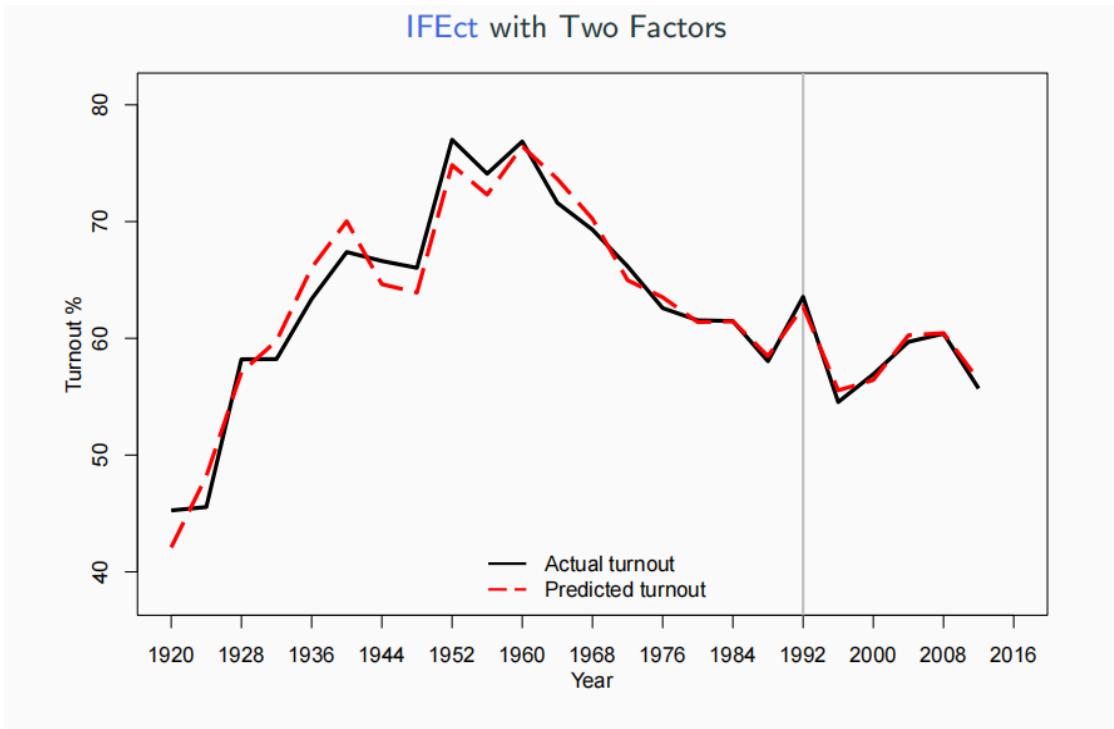
因果推断是一个数据缺失的问题



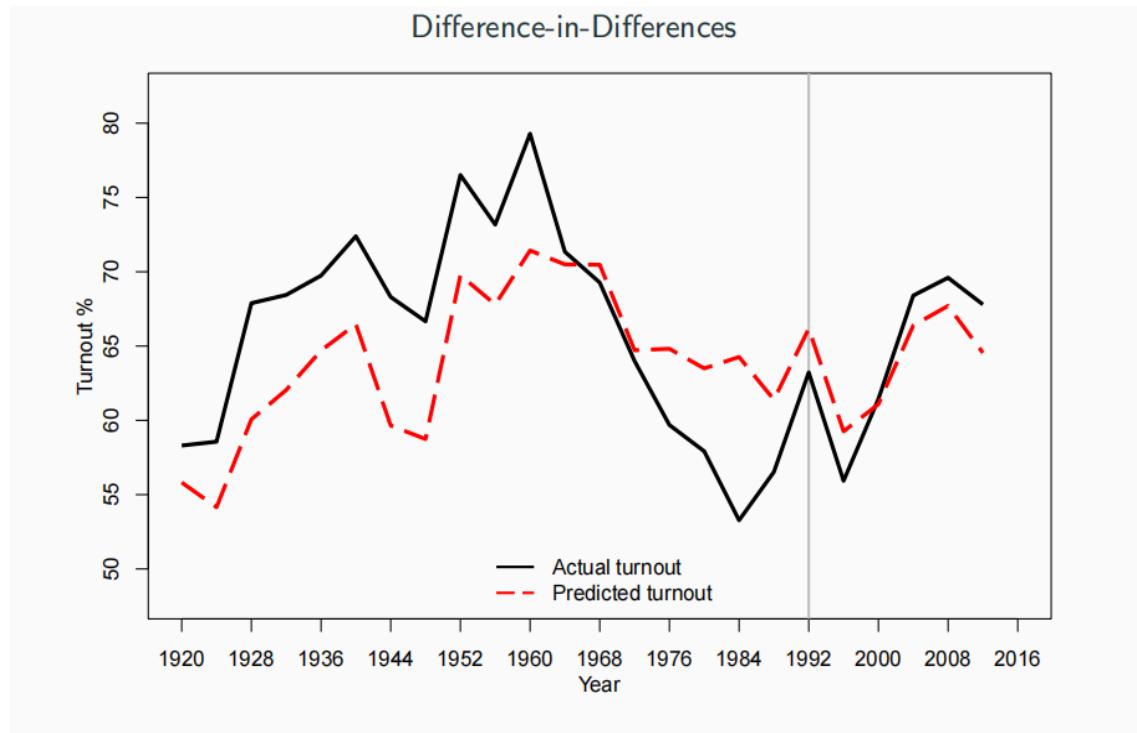
康涅狄格州的案例



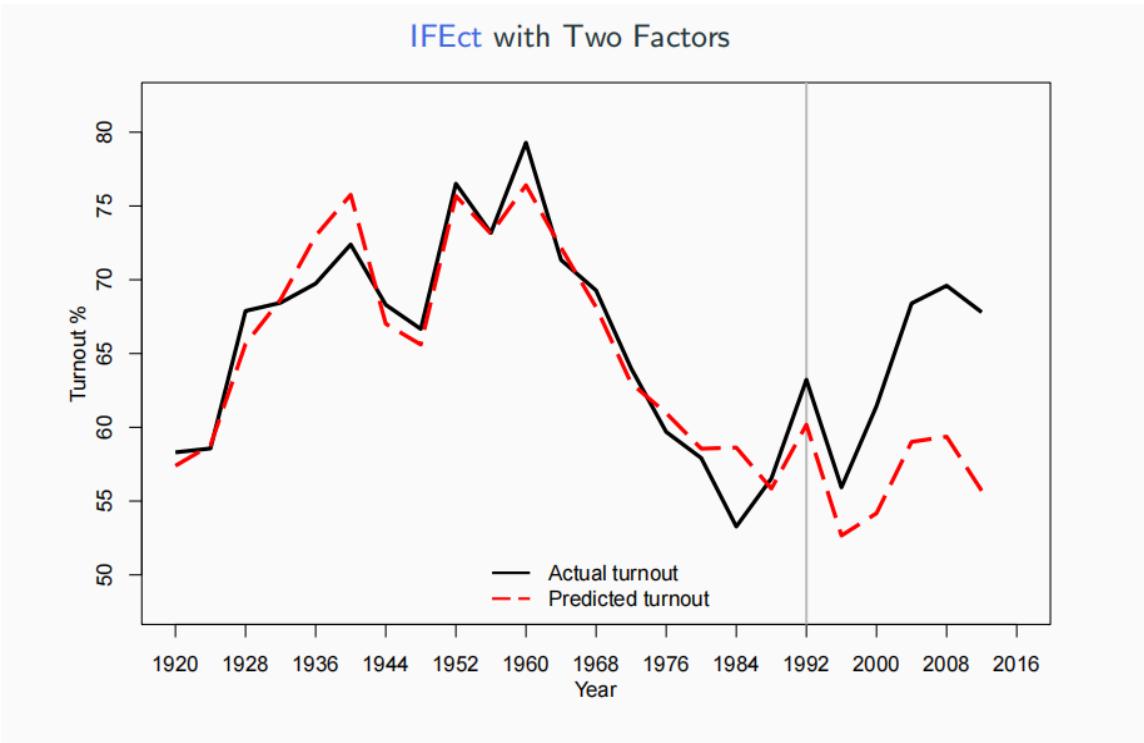
康涅狄格州的案例



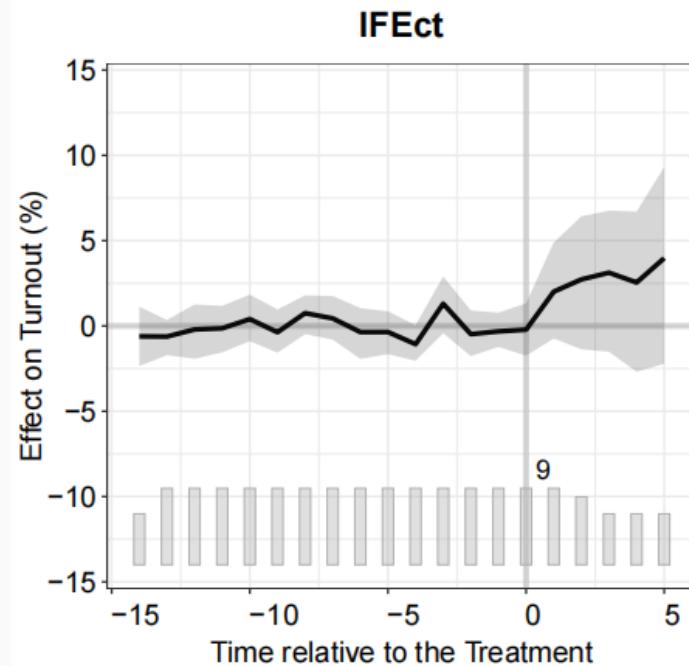
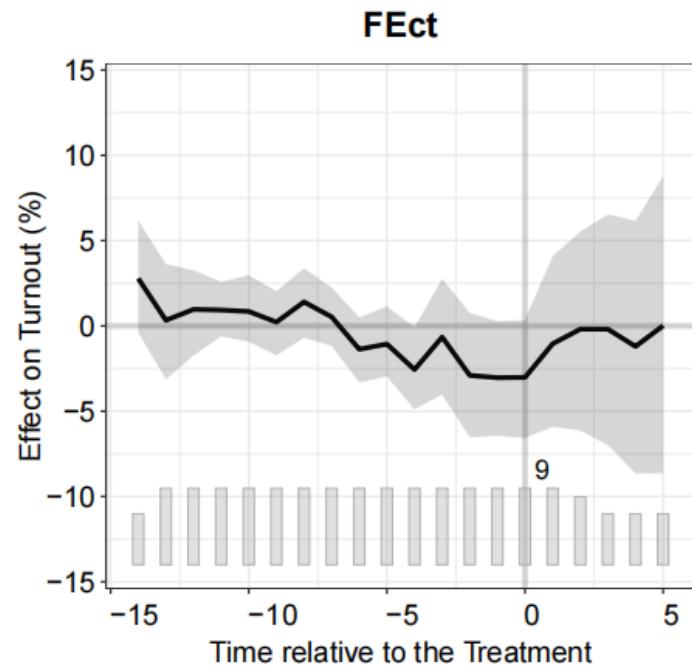
康涅狄格州的案例



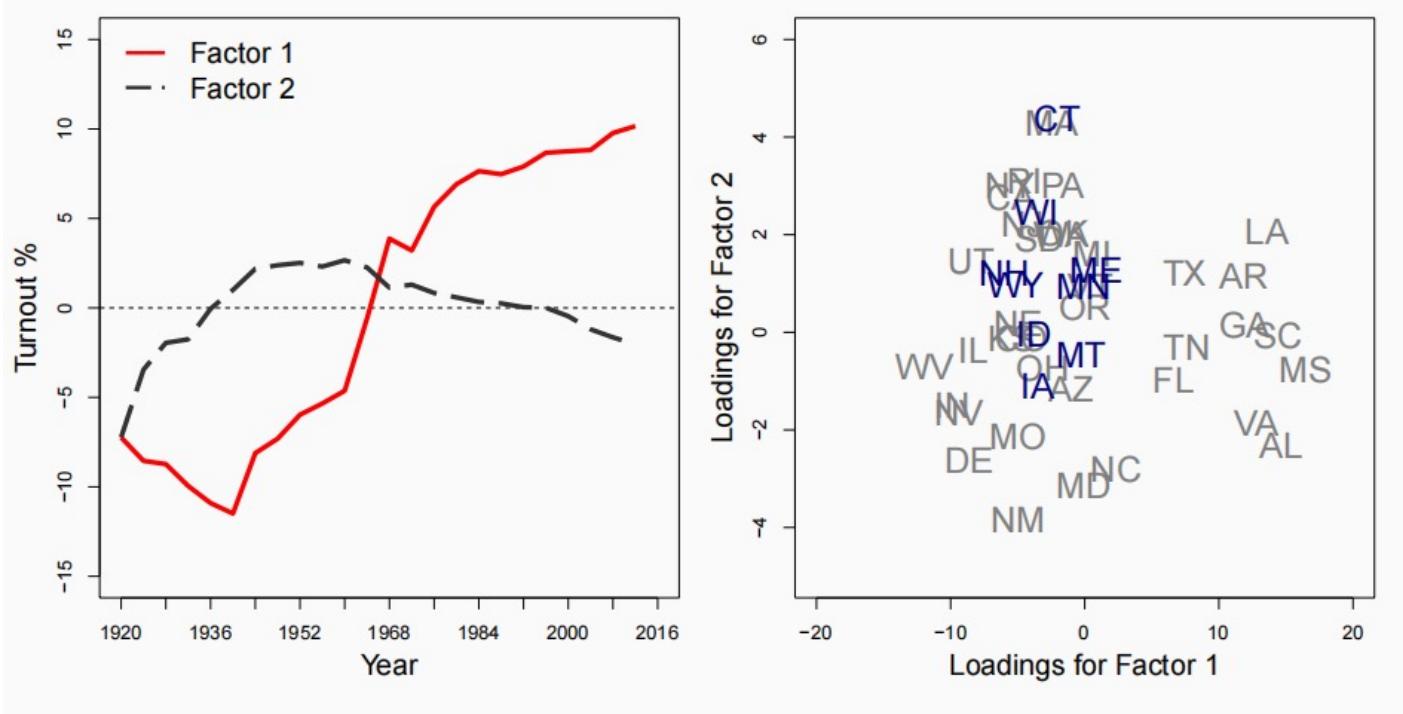
康涅狄格州的案例



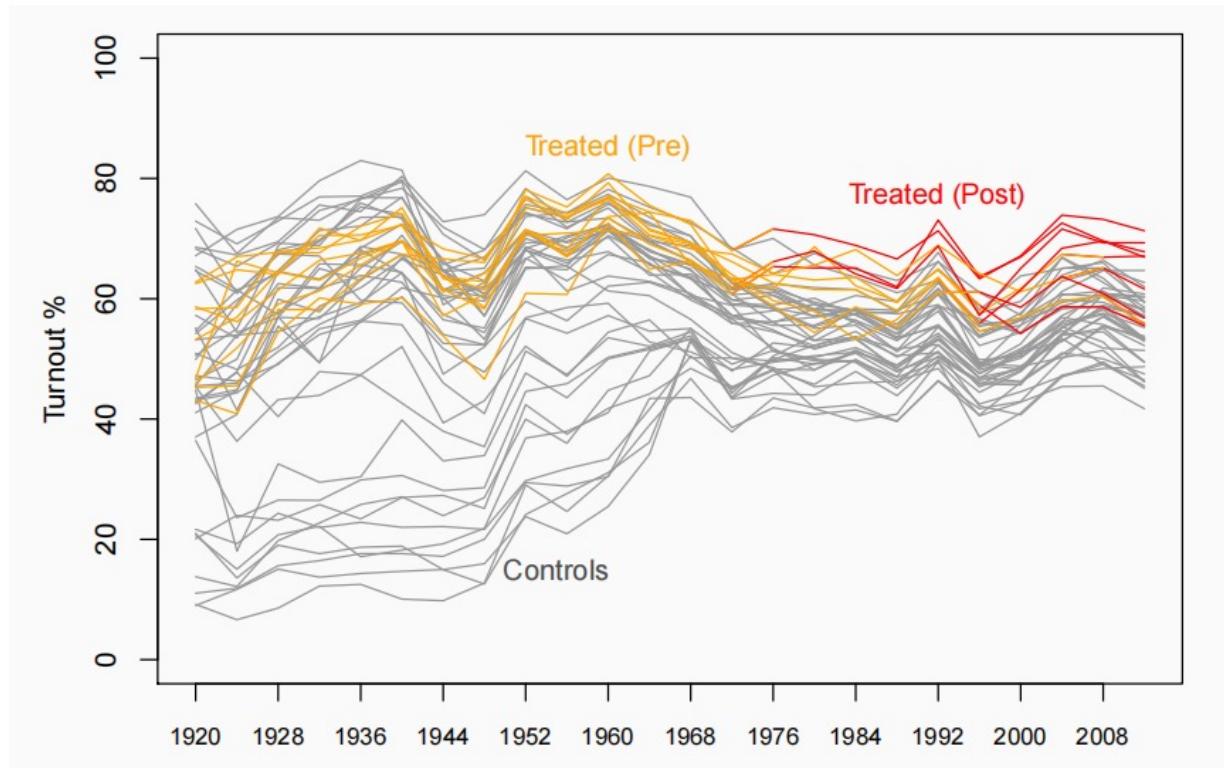
主要结果



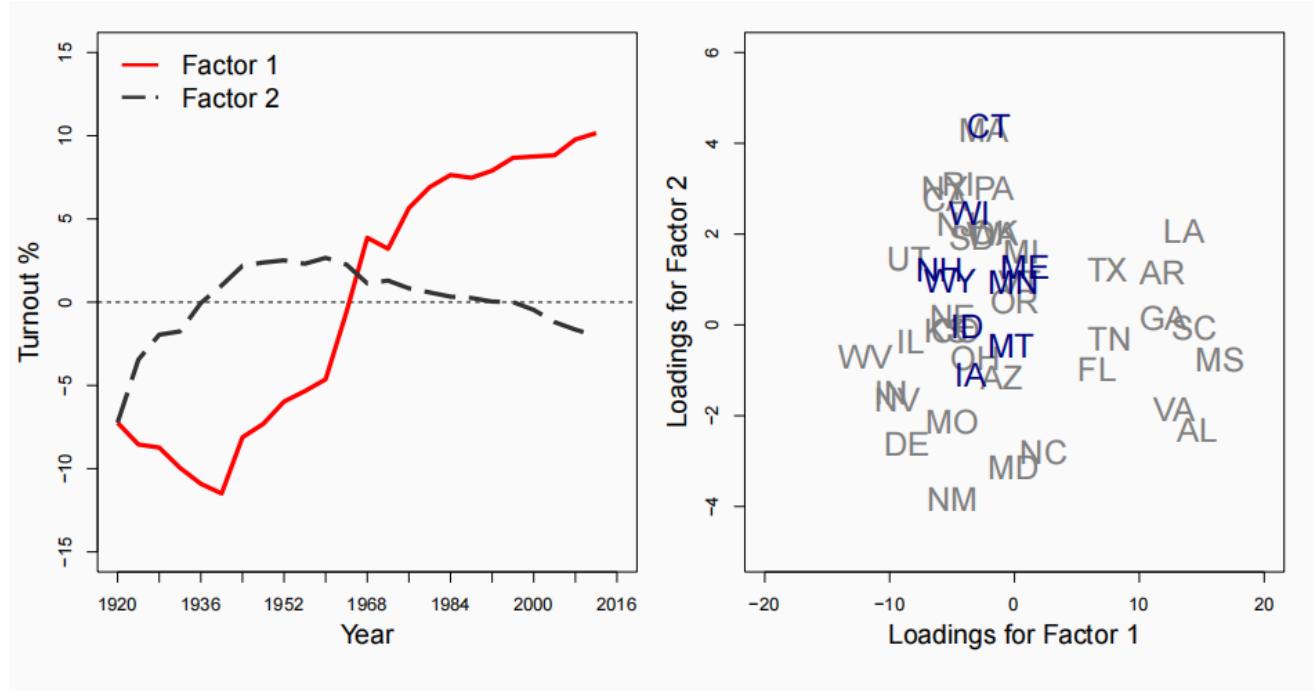
因子和因子载荷



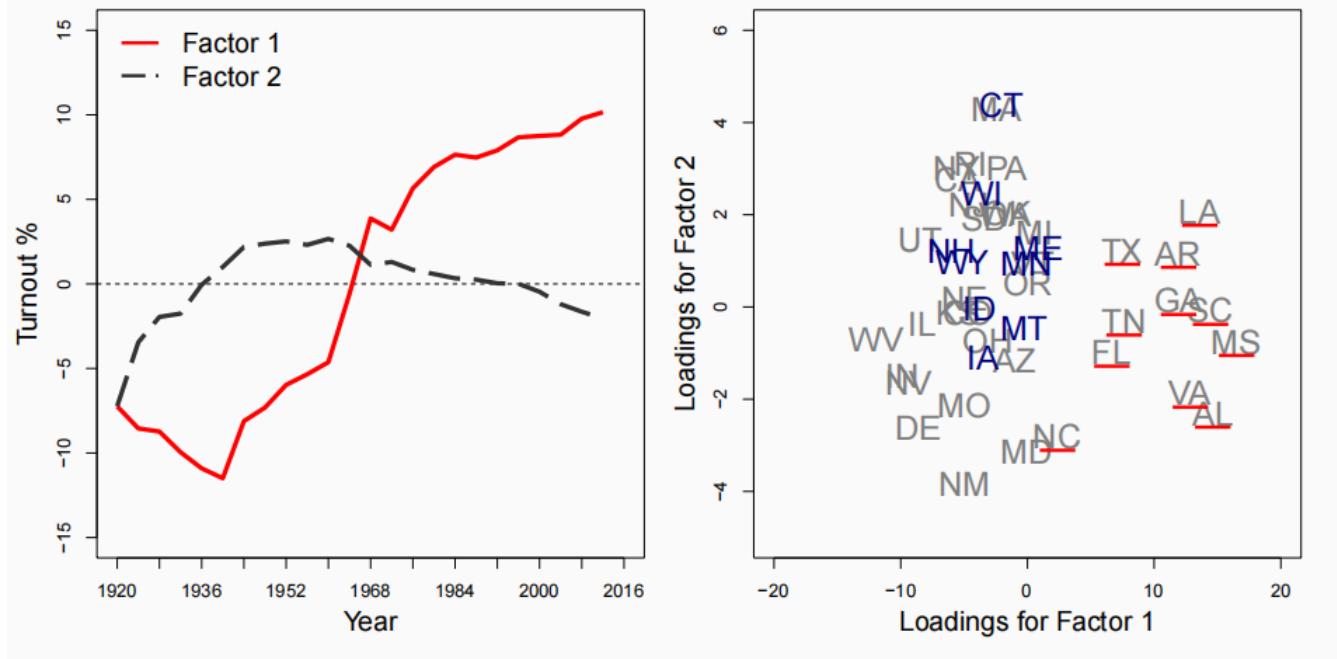
因子和因子载荷



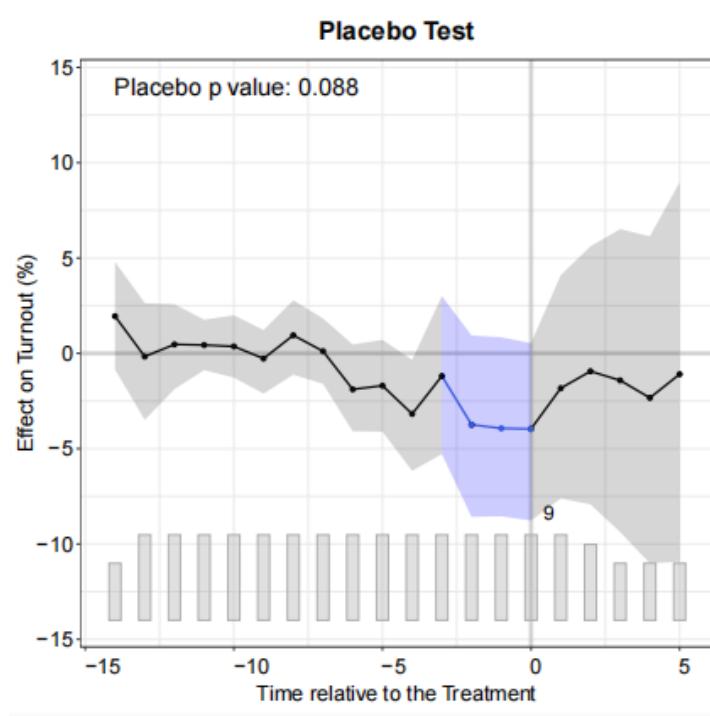
因子和因子载荷



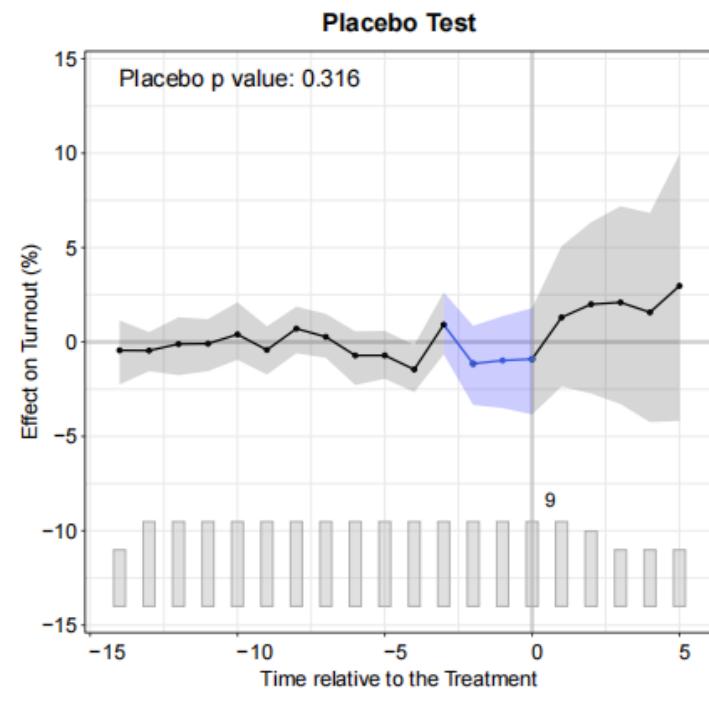
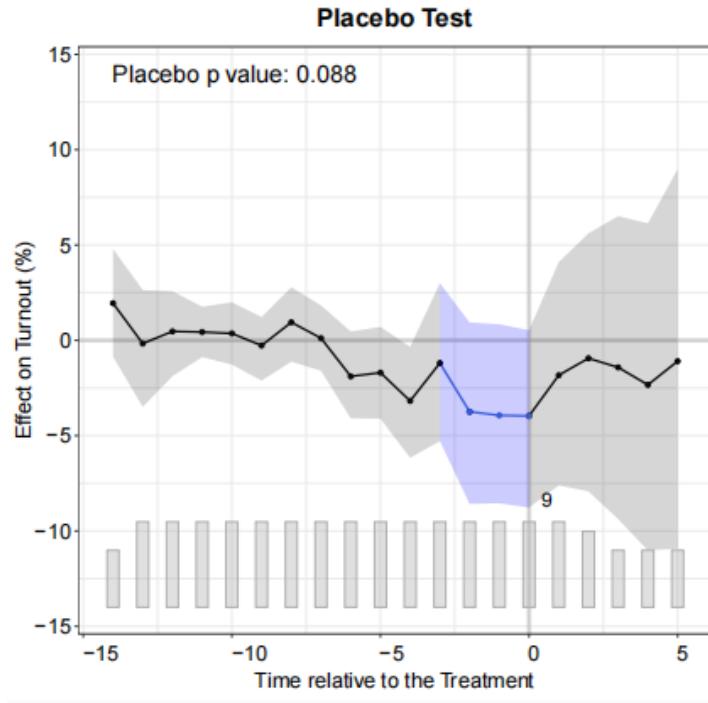
因子和因子载荷



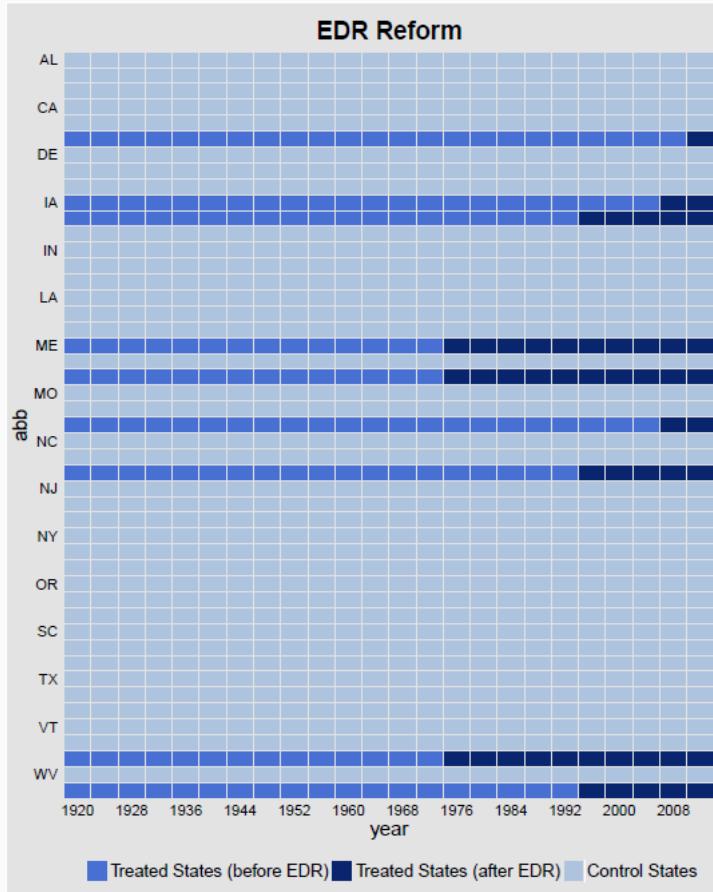
安慰剂检验



安慰剂检验

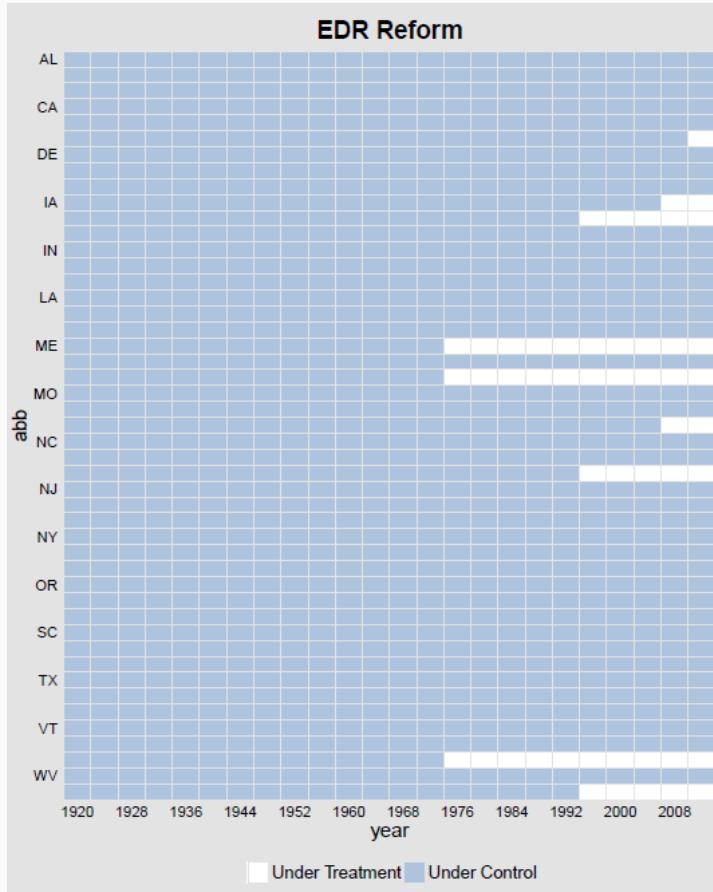


矩阵补全方法



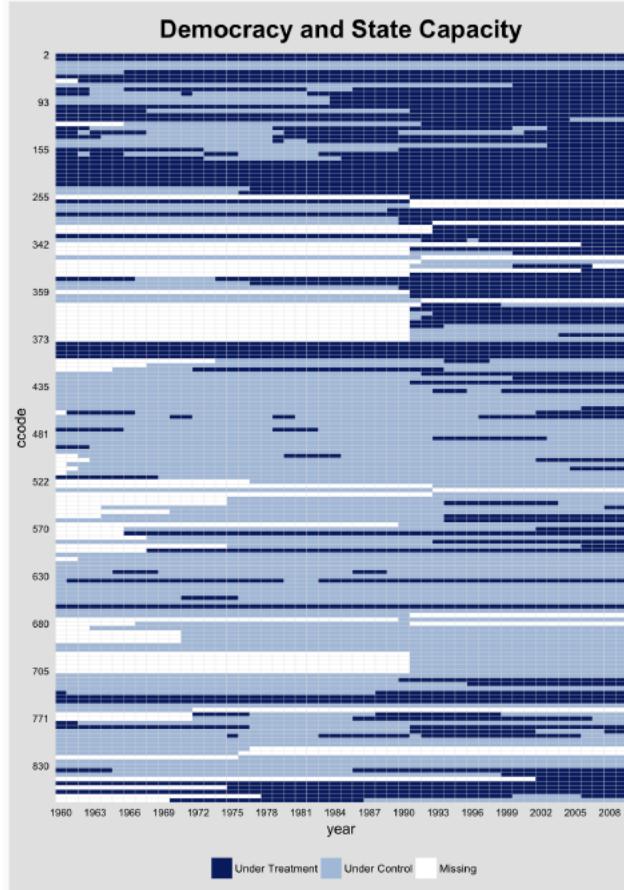
- 回想一下，我们的主要目标是预测处理组的反事实
- 利用矩阵结构，矩阵补全方法使用未经处理的数据来实现这一目标

矩阵补全方法



- 回想一下，我们的主要目标是预测处理组的反事实
- 利用矩阵结构，矩阵补全方法使用未经处理的数据来实现这一目标
- 基本思想是找到矩阵的低秩表示来估算“缺失数据”
- Xu(2017)是这种方法的一个特例

矩阵补全方法



- 回想一下，我们的主要目标是预测处理组的反事实
- 利用矩阵结构，矩阵补全方法使用未经处理的数据来实现这一目标
- 基本思想是找到矩阵的低秩表示来估算“缺失数据”
- Xu(2017)是这种方法的一个特例

矩阵补全方法

- 回忆双重差分法 (DiD) 的最基本设定: $Y = \begin{pmatrix} Y_{\tau, pre}^0 & ?? \\ Y_{C, pre}^0 & Y_{C, post}^0 \end{pmatrix}$
- 矩阵补全 (MC) 试图找到 Y 的低秩表示, 我们称之为 L , 它可以预测 Y 中的缺失值
- Athey 等 (2021) 用不同的构建 L 的方式一般化了 Xu (2017) 的方法
- 另外, 缺失可以是任意的 → 适应可逆处理 (reversible treatment) (注意, 严格外生性)

矩阵补全方法

- 在数学上,
$$Y_{it} = \textcolor{red}{L}_{it} + \alpha_i + \xi_t + X'_{it}\beta + \varepsilon_{it}$$
- 其中 L_{it} 是 \mathbf{L} 中的一个元素, \mathbf{L} 是一个 $(N \times T)$ 的矩阵
- 由于参数太多, 我们需要对 \mathbf{L} 进行正则化:

$$\min_{\mathbf{L}} \frac{1}{\#\text{Controls}} \sum_{D_{it}=0} (Y_{it} - L_{it})^2 + \lambda_L \|L\|_*$$

- 核范数 $\|\cdot\|_*$ 通常能带来 \mathbf{L} 的低秩解

$$\|\mathbf{L}\|_* = \sum_{i=1}^{\min(N,T)} \sigma_i(\mathbf{L})$$

其中 $\sigma_i(\mathbf{L})$ 代表 L 的第 i 个奇异值

IFEct vs. MC

- L 的奇异值分解 $\mathbf{L}_{N \times T} = \mathbf{S}_{N \times N} \boldsymbol{\Sigma}_{N \times T} \mathbf{R}_{T \times T}$

$\boldsymbol{\Sigma}_{N \times T}$ 正则化方式的差异

IFE

best subset

$$\begin{pmatrix} \sigma_1 & 0 & 0 & \dots & 0 \\ 0 & \sigma_2 & 0 & \dots & 0 \\ 0 & 0 & \mathbf{0} & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & \mathbf{0} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & \dots & 0 \end{pmatrix}$$

MC

nuclear norm

$$\begin{pmatrix} |\sigma_1 - \lambda_L|_+ & 0 & 0 & \dots & 0 \\ 0 & |\sigma_2 - \lambda_L|_+ & 0 & \dots & 0 \\ 0 & 0 & |\sigma_3 - \lambda_L|_+ & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & 0 \\ 0 & 0 & 0 & \dots & |\sigma_T - \lambda_L|_+ \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & \dots & 0 \end{pmatrix}$$

其中, $|a|_+ = \max(a, 0)$

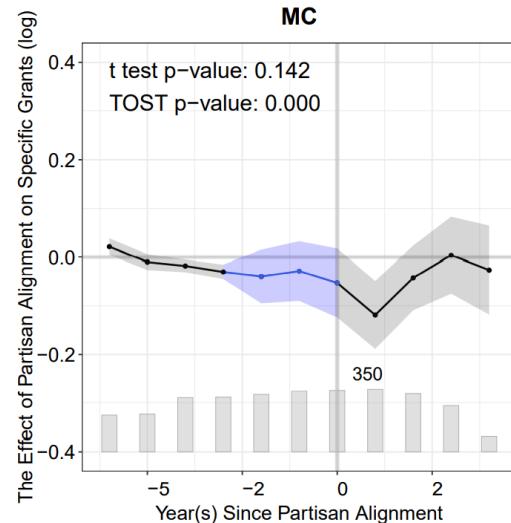
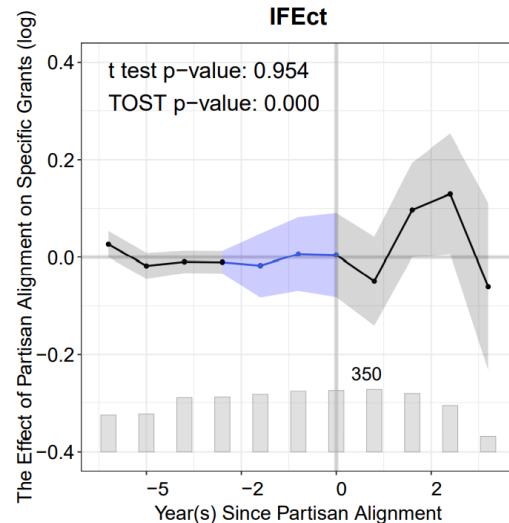
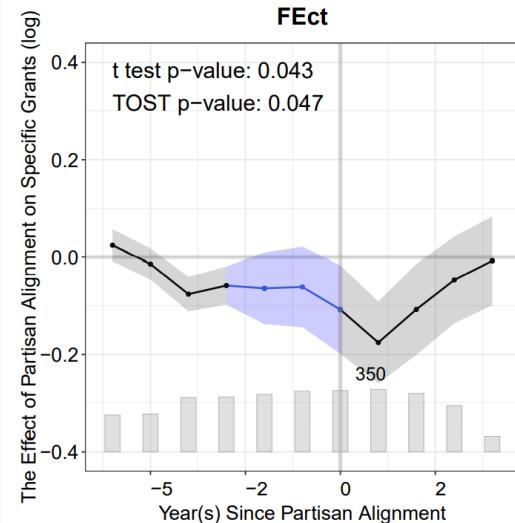
推断方法和诊断

- 非参 block bootstrap
 - 以Unit为单位可放回抽样
 - 给定 $\frac{N_{tr}}{N}$ 和 N 很大时有效
- Sharp Null 基于排列的检验 (Chernozhukov et al., 2019)
 - 例: $Y_{it}(1) = Y_{it}(0), \forall i \in \mathcal{T}, t > T_{0i}$
 - 跨时间 (按块) 随机化而不是跨单元
 - 如果T很大, 误差项是平稳弱依赖, 并且估计量一致或稳定, 则有效
 - 如果误差项满足 i.i.d, 则准确
- Liu, Wang & Xu (2022) 提出了一套诊断测试方法

Fouirnaies and Mutlu-Eren (2015)

党派结盟会给英国带来特别资助吗？

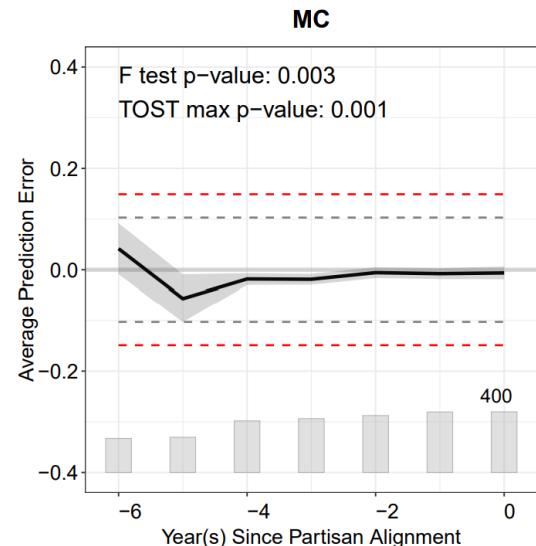
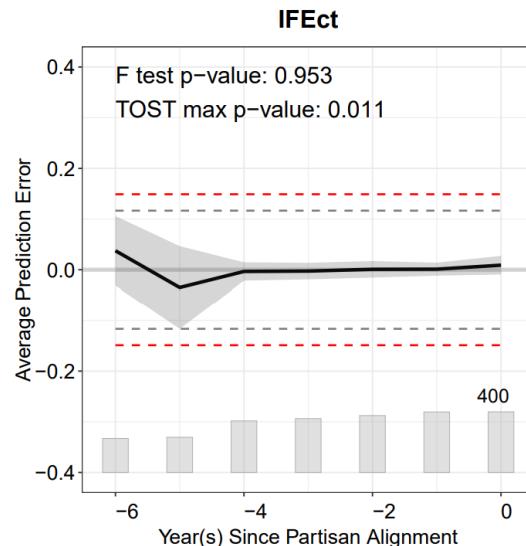
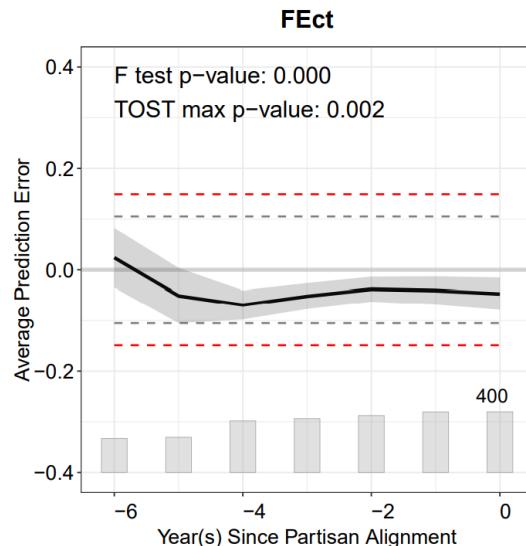
- 分析对象：1992-2012年间的466个地方议会
- 处理组：地方和中央政府之间的党派结盟
- 结果：特别资助数额 (special grant)



Fouirnaies and mutlu-Eren (2015)

党派结盟会给英国带来特别资助吗？

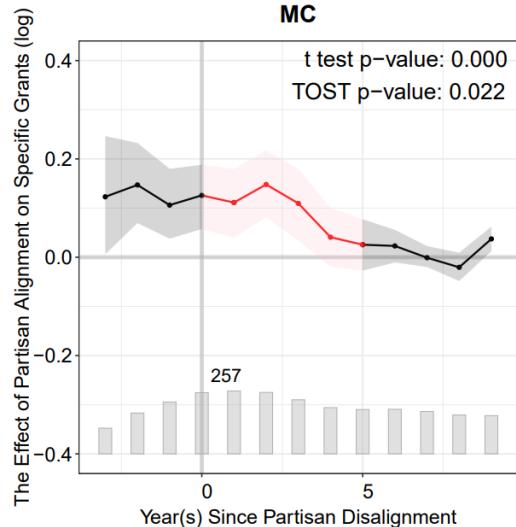
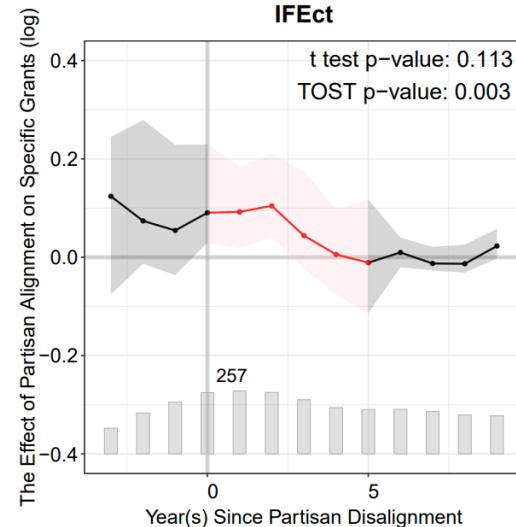
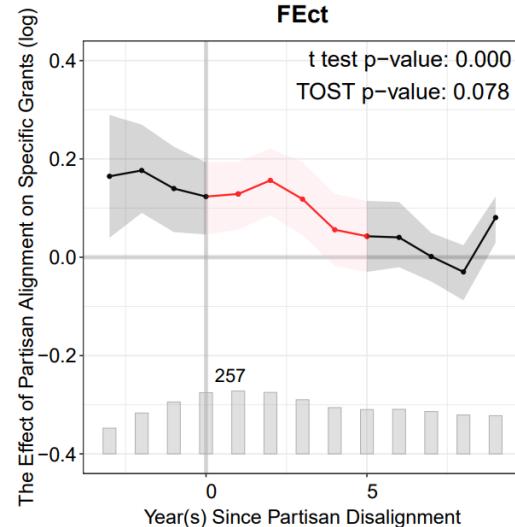
- 分析对象：1992-2012年间的466个地方议会
- 处理组：地方和中央政府之间的党派结盟
- 结果：特别资助数额 (special grant)



对 Carryover Effects 的检验

党派结盟会给英国带来特别资助吗？

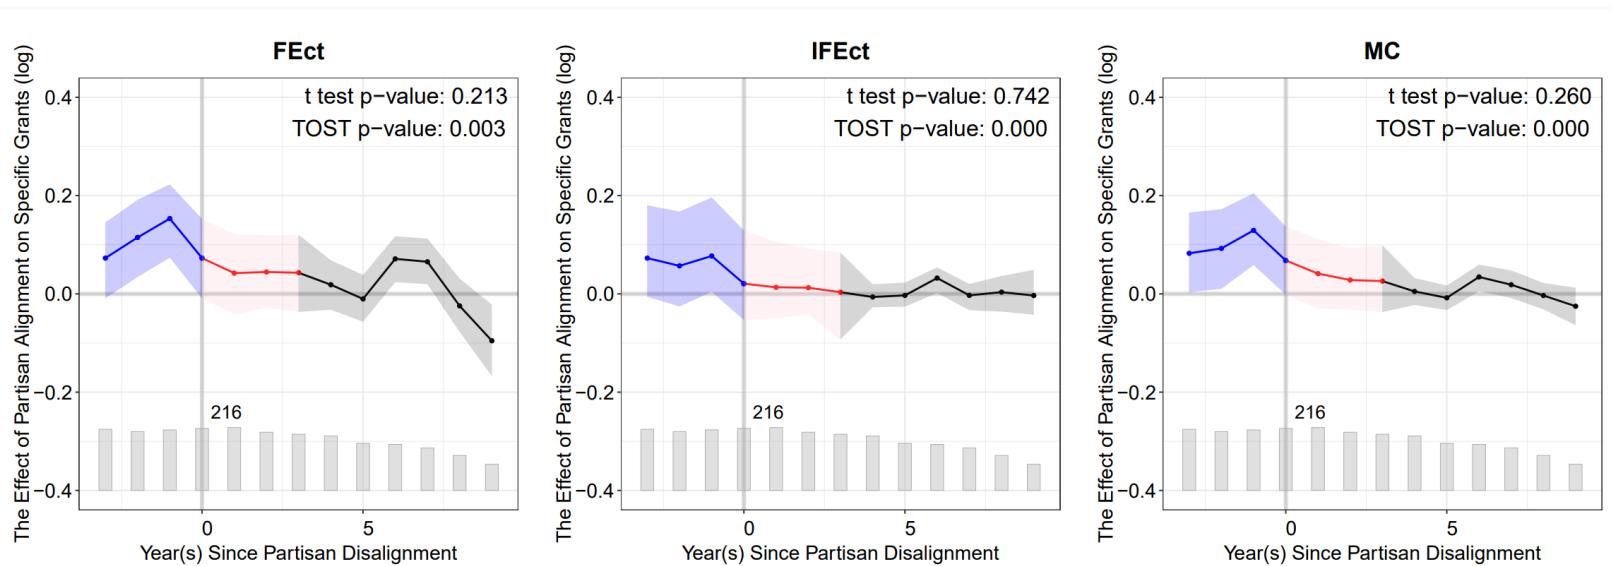
- 分析对象：1992-2012年间的466个地方议会
- 处理组：地方和中央政府之间的党派结盟
- 结果：特别资助数额（special grant）



对 Carryover Effects 的检验（去掉3期）

党派结盟会给英国带来特别资助吗？

- 分析对象：1992-2012年间的466个地方议会
- 处理组：地方和中央政府之间的党派结盟
- 结果：特别资助数额（special grant）



总结

CONCLUSIONS

总结

- 双向固定效应是非常常用的面板数据估计工具，大致有静态和动态两种设定。
- 要识别ATT，双重差分法要满足：**平行趋势、无溢出或一般均衡效应、无预期效应**
- 双向固定效应模型往往存在问题：
 - ✓ 除了需要满足双重差分法的识别假设之外
 - ✓ 还需要**同质性假设**（否则会导致负权重问题）和
 - ✓ **有限的延迟效应** (Carryover effect)
- 各种对异质性稳健的估计量，可以放松同质性假设。
- 合成控制法，和基于潜因子模型的反事实估计量，有助于放松平行趋势假设。
- 双重稳健估计法具有优秀的统计性质，但目前的实证研究案例较少（如政策交错实施）。

实证建议

- 可视化原始数据，特别是绘制处理状态图，这有助于我们直观地看到问题所在
- 思考处理组是如何分配的，自问：什么是假设性实验？ (hypothetical experiment)
- 如果你认为反馈效应很弱，先从平行趋势假设下的估计量入手，并检验是否具有处理前趋势
 - › 如：DiD, DiDM, FEct, augsynth
- 检验，检验，再检验… 无论采用哪种方法，都要进行安慰剂检验来测试你的假设前提是否合理
- 当然还要注意不确定性估计：
 - › 聚类 Bootstrap 法和 Jackknife 法是相对安全的选择（特别是当 N_{tr} 很小时）

参考文献

- Gobillon, Laurent, and Thierry Magnac (2016). “Regional Policy Evaluation: Interactive Fixed Effects and Synthetic Controls.” *Review of Economics and Statistics* 98 (3): 535–51.
- Xu, Yiqing (2017). “Generalized Synthetic Control Method: Causal Inference with Interactive Fixed Effects Models” *Political Analysis*, Vol. 25, Iss. 1, January 2017, pp. 57-76.
- Athey, Susan, Mohsen Bayati, Nikolay Doudchenko, Guido Imbens, and Khashayar Khosravi. 2021. “Matrix Completion Methods for Causal Panel Data Models.” *Journal of the American Statistical Association*, forthcoming. <https://doi.org/10.3386/w25132>.
- Sanford, Luke (2019) “Geospatial Synthetic Controls for Agricultural Impact Evaluation.” Working Paper.
- Liu, Licheng, Ye Wang, Yiqing Xu (2021). ”A Practical Guide to Counterfactual Estimators for Causal Inference with Time-Series Cross-Sectional Data.” *American Journal of Political Science*, forthcoming.
- Xun, Pang, Licheng Liu, and Yiqing Xu (2021). “A Bayesian Alternative to Synthetic Control for Comparative Case Studies”. *Political Analysis*, forthcoming.
- Ben-Michael Eli, Avi Feller, Jesse Rothstein (2018). “The Augmented Synthetic Control Method.” *Journal of the American Statistical Association*.
- Arkhangelsky, Dmitry, Susan Athey, David A. Hirshberg, Guido W. Imbens and Stefan Wager (2021). “Synthetic Difference In Differences.” *American Economic Review* 111(12): 4088–4118.